УДК 004.912

Метод построения распределенного поискового индекса на основе семантики запросов

Степан Андреевич Постнов[1], **Алексей Владимирович Платонов**[2], **Лев Кириллович Саськов**[3]

[1,2,3] Университет ИТМО, Санкт-Петербург, 197101, Российская Федерация
[1] s@pstnv.ru, [ORCID]
[2] avplatonov@itmo.ru, https://orcid.org/0000-0002-8485-1296
[3] [e-mail, ORCID]

Аннотация

Введение. [Проблема: шардирование индекса по словам, запрос из нескольких слов уходит в несколько шардов; цель работы.] **Метод.** [Граф совстречаемости слов, кластеризация, голосование документов, бюджет объёма шарда, жадное покрытие.] **Основные результаты.** [Вырождение без бюджета; `bal` против hash при равном числе шардов: 0,780 против 0,697, +0,083 [0,077; 0,089]; OOD +0,109.] **Обсуждение.** [Где применимо, ограничения, дальнейшая работа. Всего 250–400 слов, без сокращений.]

Ключевые слова

инвертированный индекс, шардирование по словам, маршрутизация запросов, граф совстречаемости, кластеризация графов, балансировка шардов

Благодарности

[финансирование (организация, номер гранта) или удалить блок]

Semantic term sharding of a search index under a shard-volume budget

Stepan A. Postnov[1], **Alexey V. Platonov**[2], **Lev K. Saskov**[3]

[1,2,3] ITMO University, Saint Petersburg, 197101, Russian Federation
[1] stepaha78@gmail.com, [ORCID]
[2] avplatonov@itmo.ru, https://orcid.org/0000-0002-8485-1296
[3] [e-mail, ORCID]

Abstract

[Translation of the Russian abstract.]

Keywords

inverted index, term sharding, query routing, co-occurrence graph, graph clustering, shard balancing

Acknowledgements

[funding or remove]

Введение

TODO: Шардирование по документам и по словам; почему hash-назначение слов ведёт запрос в несколько шардов; идея — класть в один шард слова, которые встречаются в одних запросах; без ограничения объёма кластеры вырождаются; решение — бюджет объёма шарда; цель работы (обязательна по правилам журнала) и вклад.

Связанные работы

TODO: Выбор ресурсов и селективный поиск, разбиение по словам и репликация, веса совстречаемости, алгоритмы выделения сообществ, покрытие множеств. Строка \nocite в исходнике держит 18 источников в нужном порядке; когда в тексте появятся \cite, её нужно удалить.

Метод

Постановка задачи. **TODO:** Разбиение словаря по шардам и правило хранения документа (1), покрытие запроса, совпадение выдачи с полным индексом (2), нижняя граница объёма шарда и дублирование (3).

$$\sigma:\ T \to 2^{S} \setminus \{\varnothing\}, \quad D(d) = \bigcup_{t \in d} \sigma(t), \tag{1}$$

$$\mathrm{Top}_k\Big(\bigcup_{s \in S_q} R_s(q)\Big) = \mathrm{Top}_k\big(R(q)\big), \tag{2}$$

$$\mathrm{vol}(s) \geq \max_{t:\, s \in \sigma(t)} \mathrm{df}(t), \quad \mathrm{dup} = \frac{1}{|\mathcal{D}|} \sum_{d \in \mathcal{D}} |D(d)|. \tag{3}$$

Граф совстречаемости слов. **TODO:** Вершины, пороги, слова вопросной рамки; ребро и вес NPMI (4); альтернативные веса G^2 и χ^2.

$$\mathrm{NPMI}(a,b) = \ln \frac{n(a,b)\,N}{n(a)\,n(b)} \Big/ \Big(-\ln \frac{n(a,b)}{N}\Big). \tag{4}$$

© Постнов С.А., Платонов А.В., Саськов Л.К., 2026

Построение кластеров. **TODO:** Leiden с модулярностью (5), CPM, Infomap, METIS — по одной фразе; зачем четыре алгоритма.

$$Q_\gamma = \frac{1}{2m} \sum_{i,j} \Big[A_{ij} - \gamma \, \frac{k_i k_j}{2m} \Big] \, \delta(c_i, c_j). \tag{5}$$

Шардирование документов на основе кластеров. **TODO:** Стратегии `base` и `aff` с голосованием документов (6), реплики по сродству (7), hash-разбиения на то же число шардов.

$$c^*(t) = \arg\max_{c} \ \operatorname{sgn}\Big(\frac{v(t,c)}{v(t)} - \frac{m(c)}{m} \Big) \, G^2(t,c), \tag{6}$$

$$\operatorname{aff}(t,c) = \sum_{(t,u)\in E,\ u \in c} w_{tu}. \tag{7}$$

TODO: Бюджет объёма шарда, стратегия `bal`: единицы (дробление кластеров сверх бюджета тем же алгоритмом) и упаковка по наименьшему приросту объёма (8).

$$s^*(u) = \arg \min_{s:\ \mathrm{vol}(s) + \Delta(u,s) \le \beta |\mathcal{D}|} \Delta(u,s), \tag{8}$$

где $\Delta(u,s) = \big| \mathcal{D}(u) \setminus \mathcal{D}(s) \big|$.

Маршрутизация запроса. **TODO:** Жадное покрытие с весом IDF (9), бюджет опрошенных шардов b.

$$s_i = \arg\max_{s \in S} \sum_{t \in q \setminus C_{i-1},\ s \in \sigma(t)} w(t), \tag{9}$$

где $w(t) = \ln\big(|\mathcal{D}| / (\mathrm{df}(t) + 1) \big) + 1$.

Методика оценки

Датасет. **TODO:** MS MARCO v2.1: 241 185 документов, из них 113 176 дистракторов; 122 063 запросов, 115 959 обучающих и 6 104 отложенных; граф 10 567 слов и 39 794 рёбер.

Оценочные выборки. **TODO:** train, holdout, OOD (Natural Questions), connected и frequent pairs и triples.

Метрики. **TODO:** Эталон — top-10 полного индекса; overlap и объём опроса (10); среднее число шардов в покрытии, доля запросов в один шард, дублирование; бутстреп и парные разности; срезы по связности и длине запроса.

$$\mathrm{overlap@}k(q,b) = \frac{\big| R_k(q) \cap \mathcal{D}(S_q^{(b)}) \big|}{k}. \tag{10}$$

Сравниваемые конфигурации. **TODO:** 10 стратегий на 4 алгоритма; основная конфигурация зафиксирована до измерений (бюджет 15 %, γ равно 1, зерно 42); каждая стратегия сравнивается с hash-разбиением на то же число шардов.

Результаты

Структура графа и кластеров. **TODO:** Темы крупнейших кластеров и тяжёлый хвост размеров: у Leiden 340 кластеров, крупнейший 1 563 слов.

Борьба с вырожденным кластером. **TODO:** Без бюджета крупнейший шард `aff` — 83,1 % корпуса; ужесточение параметра алгоритма и другие алгоритмы шард уменьшают, но не до бюджета (рис. 1).

Сравнение стратегий. **TODO:** Семейства стратегий на Leiden (табл. 1): overlap без бюджета куплен объёмом опроса и гигантским шардом; единственная сбалансированная стратегия — `bal`.

Сравнение сбалансированной стратегии и хэш. **TODO:** При равном числе шардов `bal` лучше hash у всех алгоритмов (табл. 2); выборки и частые запросы (рис. 2); прирост растёт со связностью и длиной запроса (рис. 3).

Корректность и воспроизводимость. **TODO:** Сверка с настоящими индексами Whoosh: 1 594 686 оценок, максимальное расхождение $3,6 \cdot 10^{-15}$, 0 расхождений выдачи; код и данные открыты.

Влияние гиперпараметров. **TODO:** Зерно, объём журнала, параметр алгоритма, 19 вариантов настроек — эффекты для `bal` в пределах 1–2 п. п.; бюджет 5–30 %: прирост над hash сохраняется.

Ограничения

TODO: Глобальная статистика BM25, один корпус и язык, дублирование около 20, оценка по прокси-стоимости, а не по задержкам.

Заключение

TODO: Основные выводы с числами, без пересказа содержания; направления дальнейшей работы.

Литература

1. Kulkarni A., Callan J. Selective search: Efficient and effective search of large textual collections // ACM Transactions on Information Systems. 2015. V. 33. N 4. P. 17:1–17:33. https://doi.org/10.1145/2738035
2. Dai Z., Xiong C., Callan J. Query-biased partitioning for selective search // Proceedings of the 25th ACM International Conference on Information and Knowledge Management (CIKM). 2016. P. 1119–1128. https://doi.org/10.1145/2983323.2983706
3. Risvik K.M., Chilimbi T., Tan H. et al. Maguro, a system for indexing and searching over very large text collections // Proceedings of the 6th ACM International Conference on Web Search and Data Mining (WSDM). 2013. P. 727–736. https://doi.org/10.1145/2433396.2433486
4. Moffat A., Webber W., Zobel J., Baeza-Yates R. A pipelined architecture for distributed text query evaluation // Information

References

1. Kulkarni A., Callan J. Selective search: Efficient and effective search of large textual collections. *ACM Transactions on Information Systems*, 2015, vol. 33, no. 4, pp. 17:1–17:33. https://doi.org/10.1145/2738035
2. Dai Z., Xiong C., Callan J. Query-biased partitioning for selective search. *Proceedings of the 25th ACM International Conference on Information and Knowledge Management (CIKM)*, 2016, pp. 1119–1128. https://doi.org/10.1145/2983323.2983706
3. Risvik K.M., Chilimbi T., Tan H. et al. Maguro, a system for indexing and searching over very large text collections. *Proceedings of the 6th ACM International Conference on Web Search and Data Mining (WSDM)*, 2013, pp. 727–736. https://doi.org/10.1145/2433396.2433486
4. Moffat A., Webber W., Zobel J., Baeza-Yates R. A pipelined architecture for distributed text query evaluation. *Information Re-*

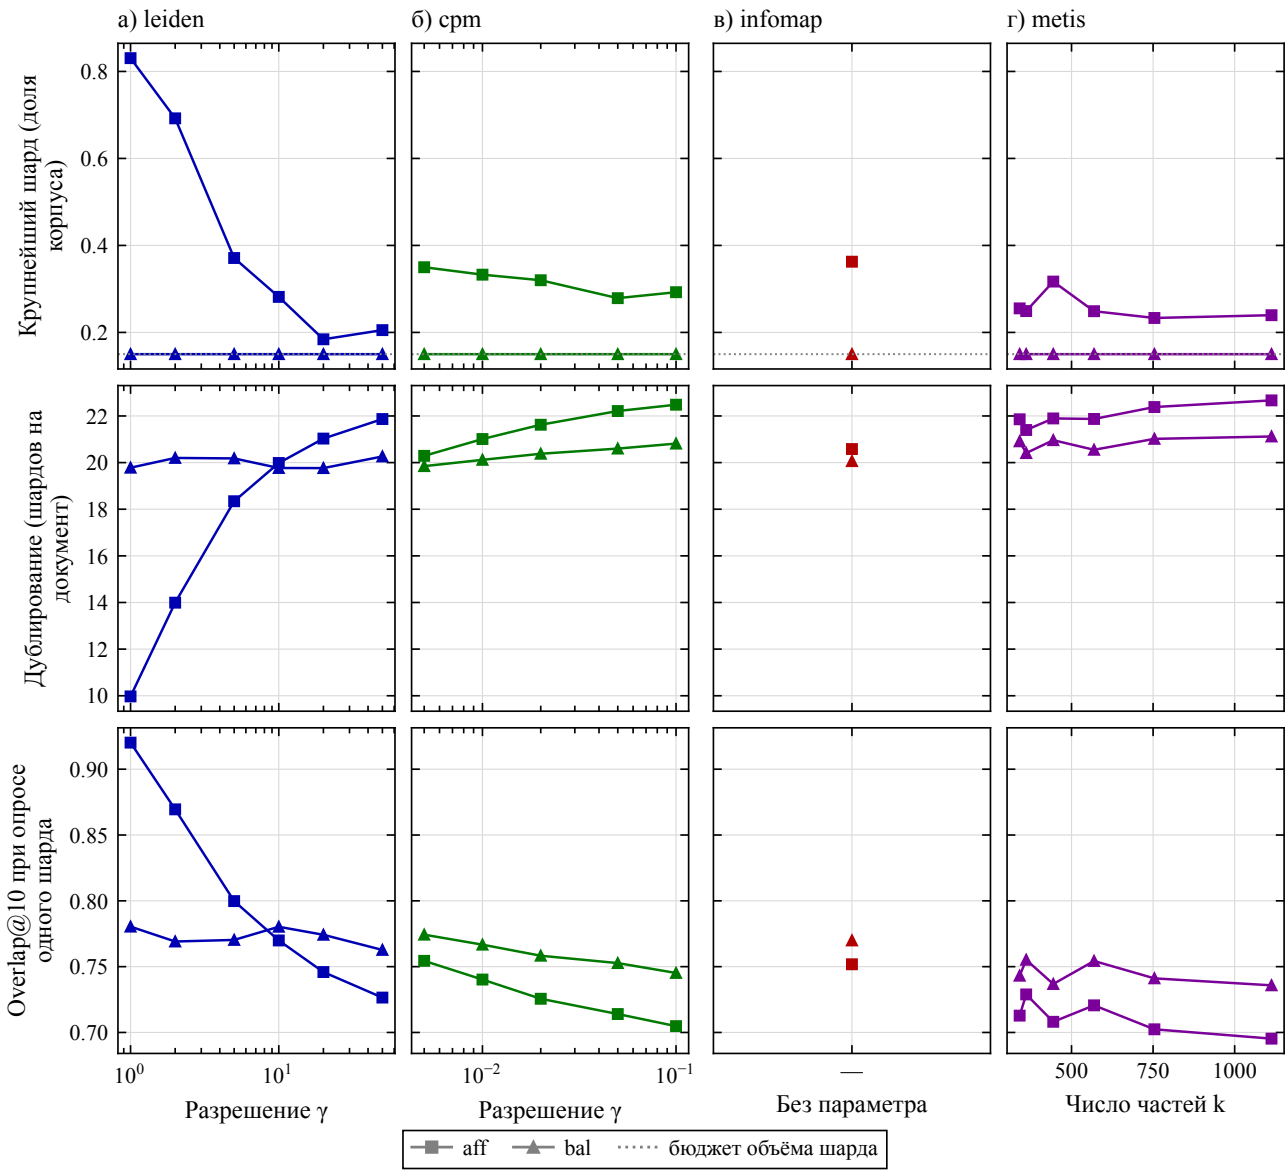


Рис. 1. Крупнейший шард, дублирование и overlap@10 при опросе одного шарда в зависимости от параметра алгоритма кластеризации для стратегий `aff` и `bal`; пунктир — бюджет объёма шарда

Fig. 1. Largest shard, duplication and overlap@10 with one shard probed against the clustering parameter for `aff` and `bal`; the dotted line is the shard-volume budget

Таблица 1. Стратегии шардирования на отложенной выборке, алгоритм Leiden

Table 1. Sharding strategies on the held-out sample, Leiden

Стратегия	Шардов	Дубл.	Макс. шард, %	Fanout	В 1 шард, %	Overlap@10		Объём опроса, %		
						@1	@2	@1	@2	полн.
`hash_base`	680	25,7	15,7	3,23	6,6	0,651	0,954	3,9	8,0	15,2
`base`	680	16,6	79,4	2,61	13,8	0,796	0,982	35,0	67,4	94,1
`base_r2`	680	19,3	95,9	2,31	19,6	0,839	0,989	52,1	89,2	110,3
`base_r3`	680	21,1	98,4	2,18	23,2	0,852	0,990	58,4	92,6	108,7
`hash_aff`	400	25,3	19,8	3,22	6,6	0,660	0,957	6,5	12,9	23,2
`aff`	400	10,0	83,1	2,31	22,7	0,920	0,997	59,5	104,5	136,5
`aff_r2`	400	12,2	96,4	1,98	31,3	0,952	0,999	75,7	126,8	149,4
`aff_r3`	400	13,8	98,6	1,85	36,5	0,962	0,999	82,4	132,6	150,1
`hash_bal`	132	23,6	31,6	3,20	6,7	0,697	0,966	17,9	35,3	60,1
`bal`	132	19,8	15,0	2,90	9,4	0,780	0,979	15,0	28,5	43,4

Retrieval. 2007. V. 10. N 3. P. 205–231. https://doi.org/10.1007/ *trieval*, 2007, vol. 10, no. 3, pp. 205–231. https://doi.org/10.1007/

Таблица 2. Парные разности `bal` и `hash_bal`: среднее и 95 %-й доверительный интервал
Table 2. Paired differences of `bal` and `hash_bal`: mean and 95 % confidence interval

Выборка	Алгоритм	Δ overlap@10 ($b = 1$)	Δ overlap@10 ($b = 2$)	Δ fanout	Δ в 1 шард	Δ объём@1
holdout	Leiden	+0,083 [0,077; 0,089]	+0,013 [0,011; 0,015]	−0,31 [−0,33; −0,29]	+0,027 [0,023; 0,031]	−0,030 [−0,031; −0,029]
holdout	CPM	+0,061 [0,056; 0,067]	+0,010 [0,008; 0,012]	−0,26 [−0,27; −0,24]	+0,020 [0,016; 0,024]	−0,025 [−0,026; −0,024]
holdout	Infomap	+0,072 [0,066; 0,078]	+0,012 [0,010; 0,015]	−0,30 [−0,31; −0,28]	+0,023 [0,019; 0,027]	−0,028 [−0,029; −0,027]
holdout	METIS	+0,045 [0,040; 0,050]	+0,008 [0,006; 0,010]	−0,15 [−0,16; −0,14]	+0,014 [0,011; 0,017]	−0,021 [−0,022; −0,020]
OOD	Leiden	+0,109 [0,104; 0,114]	+0,038 [0,034; 0,041]	−0,37 [−0,38; −0,35]	+0,003 [0,002; 0,004]	−0,030 [−0,031; −0,029]
OOD	CPM	+0,096 [0,090; 0,101]	+0,034 [0,031; 0,037]	−0,36 [−0,37; −0,34]	+0,002 [0,001; 0,003]	−0,026 [−0,027; −0,025]
OOD	Infomap	+0,106 [0,101; 0,111]	+0,038 [0,034; 0,041]	−0,39 [−0,40; −0,37]	+0,003 [0,002; 0,004]	−0,028 [−0,029; −0,028]
OOD	METIS	+0,060 [0,055; 0,065]	+0,021 [0,018; 0,024]	−0,19 [−0,20; −0,18]	+0,001 [0,000; 0,001]	−0,022 [−0,022; −0,021]

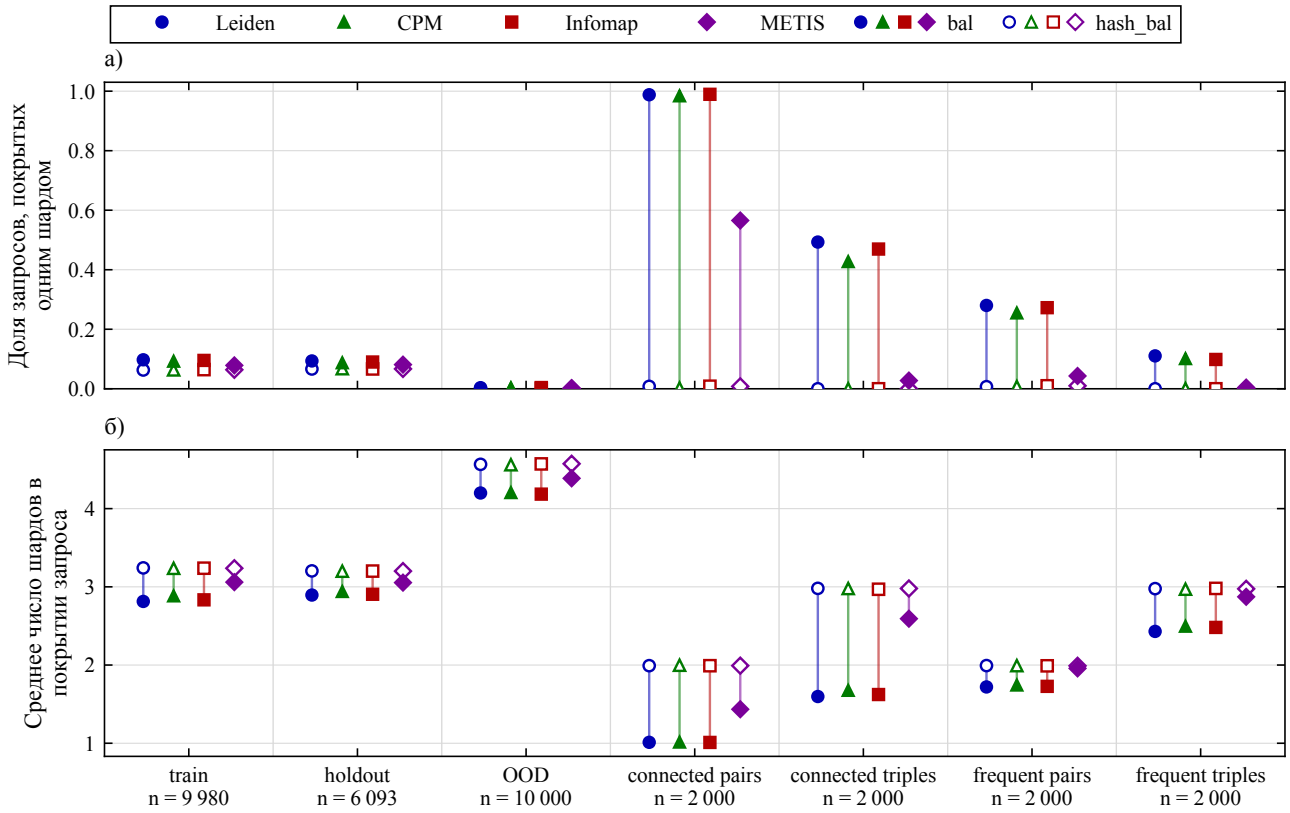


Рис. 2. Доля запросов, покрываемых одним шардом (*а*), и среднее число шардов в покрытии (*б*) по выборкам запросов: закрашенные маркеры — `bal`, полые — `hash_bal`

Fig. 2. Share of queries covered by one shard (a) and mean cover size (b) across query samples: filled markers are `bal`, hollow ones `hash_bal`

s10791-006-9014-4
5. Moffat A., Webber W., Zobel J. Load balancing for term-distributed parallel retrieval // Proceedings of the 29th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval. 2006. P. 348–355. https://doi.org/10.1145/1148170.1148232
6. Bouma G. Normalized (pointwise) mutual information in collocation extraction // Proceedings of the Biennial GSCL Conference. 2009. P. 31–40.
7. Williams C.K.I. On suspicious coincidences and pointwise mutual information // Neural Computation. 2022. V. 34. N 10. P. 2037–2046. https://doi.org/10.1162/neco_a_01533
8. Dunning T. Accurate methods for the statistics of surprise and coincidence // Computational Linguistics. 1993. V. 19. N 1. P. 61–74. https://aclanthology.org/J93-1003
9. Robertson S., Zaragoza H. The probabilistic relevance framework: BM25 and beyond // Foundations and Trends in Information Retrieval. 2009. V. 3. N 4. P. 333–389. https://doi.org/10.1561/1500000019
10. Newman M.E.J., Girvan M. Finding and evaluating community structure in networks // Physical Review E. 2004. V. 69. N 2. P.

s10791-006-9014-4
5. Moffat A., Webber W., Zobel J. Load balancing for term-distributed parallel retrieval. *Proceedings of the 29th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, 2006, pp. 348–355. https://doi.org/10.1145/1148170.1148232
6. Bouma G. Normalized (pointwise) mutual information in collocation extraction. *Proceedings of the Biennial GSCL Conference*, 2009, pp. 31–40.
7. Williams C.K.I. On suspicious coincidences and pointwise mutual information. *Neural Computation*, 2022, vol. 34, no. 10, pp. 2037–2046. https://doi.org/10.1162/neco_a_01533
8. Dunning T. Accurate methods for the statistics of surprise and coincidence. *Computational Linguistics*, 1993, vol. 19, no. 1, pp. 61–74. https://aclanthology.org/J93-1003
9. Robertson S., Zaragoza H. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 2009, vol. 3, no. 4, pp. 333–389. https://doi.org/10.1561/1500000019
10. Newman M.E.J., Girvan M. Finding and evaluating community structure in networks. *Physical Review E*, 2004, vol. 69, no. 2, pp. 026113.

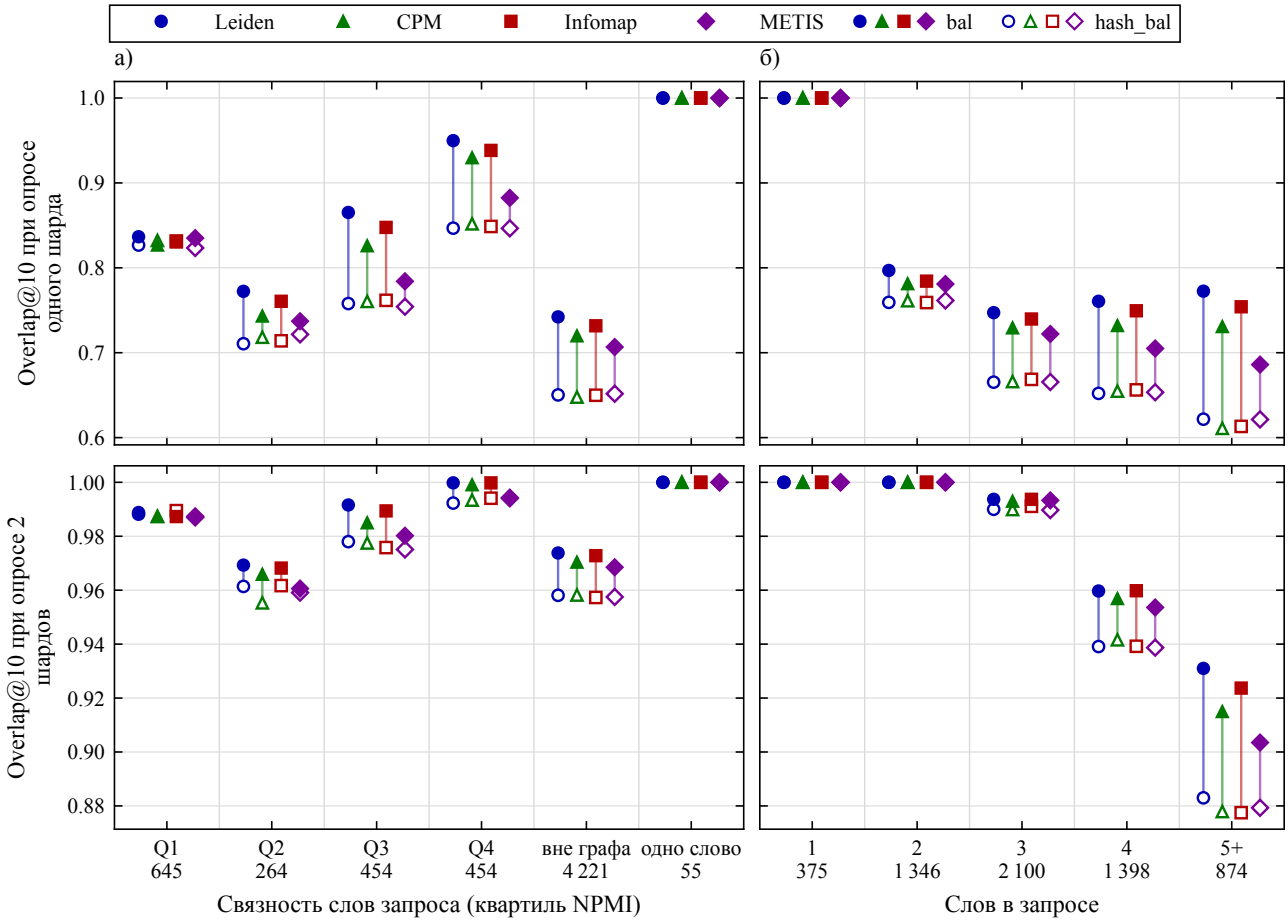


Рис. 3. Overlap@10 при опросе одного и двух шардов по срезам отложенной выборки: связность слов запроса (*а*) и число слов в запросе (*б*)

Fig. 3. Overlap@10 with one and two shards probed on slices of the held-out sample: connectivity of the query terms (a) and query length (b)

026113. https://doi.org/10.1103/PhysRevE.69.026113
11. Reichardt J., Bornholdt S. Statistical mechanics of community detection // Physical Review E. 2006. V. 74. N 1. P. 016110. https://doi.org/10.1103/PhysRevE.74.016110
12. Traag V.A., Waltman L., van Eck N.J. From Louvain to Leiden: guaranteeing well-connected communities // Scientific Reports. 2019. V. 9. N 1. P. 5233. https://doi.org/10.1038/s41598-019-41695-z
13. Traag V.A., Van Dooren P., Nesterov Y. Narrow scope for resolution-limit-free community detection // Physical Review E. 2011. V. 84. N 1. P. 016114. https://doi.org/10.1103/PhysRevE.84.016114
14. Rosvall M., Bergstrom C.T. Maps of random walks on complex networks reveal community structure // Proceedings of the National Academy of Sciences. 2008. V. 105. N 4. P. 1118–1123. https://doi.org/10.1073/pnas.0706851105
15. Karypis G., Kumar V. A fast and high quality multilevel scheme for partitioning irregular graphs // SIAM Journal on Scientific Computing. 1998. V. 20. N 1. P. 359–392. https://doi.org/10.1137/S1064827595287997
16. Chvátal V. A greedy heuristic for the set-covering problem // Mathematics of Operations Research. 1979. V. 4. N 3. P. 233–235. https://doi.org/10.1287/moor.4.3.233
17. Bajaj P., Campos D., Craswell N. et al. MS MARCO: A human generated MAchine Reading COmprehension dataset // arXiv preprint arXiv:1611.09268. 2016. https://doi.org/10.48550/arXiv.1611.09268
18. Kwiatkowski T., Palomaki J., Redfield O. et al. Natural Questions: a benchmark for question answering research // Transactions of the Association for Computational Linguistics. 2019. V. 7. P. 453–466. https://doi.org/10.1162/tacl_a_00276

https://doi.org/10.1103/PhysRevE.69.026113
11. Reichardt J., Bornholdt S. Statistical mechanics of community detection. *Physical Review E*, 2006, vol. 74, no. 1, pp. 016110. https://doi.org/10.1103/PhysRevE.74.016110
12. Traag V.A., Waltman L., van Eck N.J. From Louvain to Leiden: guaranteeing well-connected communities. *Scientific Reports*, 2019, vol. 9, no. 1, pp. 5233. https://doi.org/10.1038/s41598-019-41695-z
13. Traag V.A., Van Dooren P., Nesterov Y. Narrow scope for resolution-limit-free community detection. *Physical Review E*, 2011, vol. 84, no. 1, pp. 016114. https://doi.org/10.1103/PhysRevE.84.016114
14. Rosvall M., Bergstrom C.T. Maps of random walks on complex networks reveal community structure. *Proceedings of the National Academy of Sciences*, 2008, vol. 105, no. 4, pp. 1118–1123. https://doi.org/10.1073/pnas.0706851105
15. Karypis G., Kumar V. A fast and high quality multilevel scheme for partitioning irregular graphs. *SIAM Journal on Scientific Computing*, 1998, vol. 20, no. 1, pp. 359–392. https://doi.org/10.1137/S1064827595287997
16. Chvátal V. A greedy heuristic for the set-covering problem. *Mathematics of Operations Research*, 1979, vol. 4, no. 3, pp. 233–235. https://doi.org/10.1287/moor.4.3.233
17. Bajaj P., Campos D., Craswell N. et al. MS MARCO: A human generated MAchine Reading COmprehension dataset. *arXiv preprint arXiv:1611.09268*, 2016. https://doi.org/10.48550/arXiv.1611.09268
18. Kwiatkowski T., Palomaki J., Redfield O. et al. Natural Questions: a benchmark for question answering research. *Transactions of the Association for Computational Linguistics*, 2019, vol. 7, pp. 453–466. https://doi.org/10.1162/tacl_a_00276

Авторы

Постнов Степан Андреевич — студент, Университет ИТМО, Санкт-Петербург, 197101, Российская Федерация, stepaha78@gmail.com [ORCID]

Платонов Алексей Владимирович — кандидат технических наук, доцент, доцент, Университет ИТМО, Санкт-Петербург, 197101, Российская Федерация, https://orcid.org/0000-0002-8485-1296, avplatonov@itmo.ru

Саськов Лев Кириллович — Университет ИТМО, Санкт-Петербург, 197101, Российская Федерация [должность, ORCID, e-mail]

Authors

Stepan A. Postnov — Student, ITMO University, Saint Petersburg, 197101, Russian Federation, stepaha78@gmail.com

Alexey V. Platonov — PhD, Associate Professor, ITMO University, Saint Petersburg, 197101, Russian Federation, https://orcid.org/0000-0002-8485-1296, avplatonov@itmo.ru

Lev K. Saskov — ITMO University, Saint Petersburg, 197101, Russian Federation