УДК 004.912

Метод построения распределенного поискового индекса на основе семантики запросов

Степан Андреевич Постнов[1], Алексей Владимирович Платонов[2], Лев Кириллович Саськов[3]

[1,2,3] Университет ИТМО, Санкт-Петербург, 197101, Российская Федерация
[1] s@pstnv.ru, [ORCID]
[2] avplatonov@itmo.ru, https://orcid.org/0000-0002-8485-1296
[3] [e-mail, ORCID]

Аннотация

Введение. Распределённый поисковый индекс разрезается по документам либо по словам. При разбиении по словам инвертированный список терма хранится в одном шарде целиком, документ — в шардах всех своих термов, поэтому запрос из нескольких слов обслуживается несколькими шардами, и при случайном назначении слов их число приближается к длине запроса. Работа рассматривает размещение слов по шардам, при котором слова одного запроса попадают в один шард. **Метод.** Предложен метод шардирования по графу совстречаемости слов журнала запросов. Кластеризация графа задаёт разбиение словаря, вне-графовые слова присоединяются к кластерам голосованием документов, бюджет объёма ограничивает долю корпуса в одном шарде, маршрутизация выбирает опрашиваемые шарды жадным взвешенным покрытием. Реализация охватывает четыре алгоритма кластеризации и десять стратегий, включая случайные разбиения с равным числом шардов в качестве базовой линии. **Основные результаты.** На корпусе MS MARCO из 241 185 документов и 122 063 запросов показано, что разбиения без бюджета объёма вырождаются: крупнейший шард накапливает 83,1 % корпуса, и ни изменение параметра кластеризации, ни 18 вариаций настройки графа не приводят его к 15-процентному бюджету. Сбалансированная стратегия при равном числе шардов превосходит случайную по всем измеренным метрикам: overlap@10 при опросе одного шарда составляет 0,780 против 0,697 (парная разность +0,083; 95 %-й доверительный интервал [0,077; 0,089]), на смещённом распределении запросов прирост равен +0,109 [0,104; 0,114]. Сформулировано правило выбора конфигурации под четыре профиля нагрузки: минимальный fanout, минимальное дублирование, равномерное распределение объёма шардов, фиксированный объём опроса. **Обсуждение.** Правило выбора и соответствие между ограничением эксплуатации и параметром метода не зависят от корпуса; численные значения посчитаны для одного корпуса и одного журнала запросов. Метод предполагает глобальную статистику ранжирования BM25 и дублирование порядка двадцати копий документа. Направления дальнейшей работы — перебор бюджета объёма, реплики сбалансированной стратегии, измерение задержек вместо прокси-стоимости.

Ключевые слова

инвертированный индекс, шардирование по словам, маршрутизация запросов, граф совстречаемости, кластеризация графов, балансировка шардов

Благодарности

[финансирование (организация, номер гранта) или удалить блок]

Semantic term sharding of a search index under a shard-volume budget

Stepan A. Postnov[1], Alexey V. Platonov[2], Lev K. Saskov[3]

[1,2,3] ITMO University, Saint Petersburg, 197101, Russian Federation
[1] stepaha78@gmail.com, [ORCID]
[2] avplatonov@itmo.ru, https://orcid.org/0000-0002-8485-1296
[3] [e-mail, ORCID]

Abstract

[Translation of the Russian abstract.]

Keywords

inverted index, term sharding, query routing, co-occurrence graph, graph clustering, shard balancing

Acknowledgements

[funding or remove]

Введение

Распределённый поисковый индекс строится двумя способами. При разбиении по документам каждый шард содержит подвыборку корпуса и весь словарь, а запрос направляется в несколько шардов, выбранных оценкой распределения релевантных документов (селективный поиск) [1, 2]. При разбиении по словам словарь разрезается между шардами: инвертированный список терма хранится целиком в одном шарде, документ — в шардах всех своих термов. На таком хранении строятся конвейерные системы распределённо-

© Постнов С.А., Платонов А.В., Саськов Л.К., 2026

го вычисления запроса [3] и крупные индексные системы с терм-распределённым хранением [4]. Разрезание словаря исключает дублирование постингов и облегчает балансировку длин списков [5], но запрос из m слов затрагивает шарды всех своих термов, и маршрутизация становится основной статьёй стоимости обращения к индексу.

Назначение слов по хешу не требует настройки, но не использует структуру нагрузки: шарды запроса почти не пересекаются, и средний запрос рассматриваемого корпуса — 3,2 слова — опрашивает 3,2 шарда из 132. Если размещать вместе слова, встречающиеся в одних запросах, запрос целиком обслуживается одним шардом. Источником информации о совместной встречаемости служит журнал запросов, который поисковая система накапливает в процессе работы; построение графа совстречаемости не требует разметки и дополнительного обхода корпуса.

Кластеризация графа совстречаемости — необходимое, но не достаточное условие практичного разбиения. Документ хранится в шардах всех своих слов, поэтому кластер частых слов собирает большую часть корпуса: в проведённых измерениях крупнейший шард достигал 83,1 % корпуса. Разбиение с таким шардом непригодно для кластера равноправных узлов: хранение и трафик концентрируются на одном узле. В работе равномерность обеспечивается явным бюджетом объёма шарда.

Цель работы — метод построения разбиения словаря по графу совстречаемости слов запросов с бюджетом объёма шарда. Вклад работы состоит в следующем: предложен метод шардирования с четырьмя заменяемыми алгоритмами кластеризации и его открытая реализация; разработана воспроизводимая методика оценки на реальном журнале запросов, включая сверку расчётной выдачи шардов с физическими индексами; сформулировано правило выбора конфигурации под четыре профиля нагрузки.

Далее в разделе 2 дан обзор родственных работ, в разделе 3 описан метод, в разделе 4 — методика оценки, в разделе 5 приведены результаты, в разделе 6 обсуждаются ограничения.

Связанные работы

Селективный поиск по разбиению документов исследован в работах [1, 2]: для каждого шарда оценивается вероятность содержать релевантные документы, и запрос направляется в ограниченное подмножество шардов; разбиение может учитывать и запросную нагрузку [2]. Терм-распределённое хранение рассматривалось в системе Maguro [4] и в конвейерной архитектуре вычисления запроса [3], где запрос декомпозируется по термам и пересекается по постинговым спискам. Балансировка терм-распределённого поиска [5] перераспределяет списки между процессорами по измеренной нагрузке. В перечисленных работах критериями служат длины списков и частоты термов; объём хранимых на узле документов как ограничение, насколько известно авторам, не рассматривался. В настоящей работе именно этот объём — первичный параметр: бюджет доли корпуса в шарде определяет число шардов и равномерность узлов.

Вес ребра графа совстречаемости — мера ассоциации пары слов. Использован нормализованный pointwise mutual information (NPMI) [6], устраняющий смещение PMI в пользу редких пар; патологии немаркированной PMI разобраны в [7]. Альтернативные веса — статистика G^2 [8] и χ^2; чувствительность к выбору веса и порогов графа проверена в разделе 5.

Кластеризация графа выполняется четырьмя алгоритмами, представляющими разные принципы: максимизация модулярности [9] (реализация Leiden [10] с гарантией связности сообществ), качество constant Potts model [11] и его связь с пределом разрешения [12], минимизация ожидаемой длины кода случайного блуждания (Infomap) [13] и многоуровневая минимизация сечения графа (METIS) [14]. Выбор алгоритма в методе — заменяемый компонент; устойчивость выводов к этому выбору проверяется измерениями.

Маршрутизация запроса к шардам формулируется как взвешенное покрытие множества термов; жадный алгоритм покрытия восходит к [15]. Ранжирование выполнено по BM25 [16]. Корпус и запросы взяты из MS MARCO [17]; для проверки устойчивости к смещению распределения запросов — из Natural Questions [18].

Метод

Постановка задачи. Пусть T — словарь корпуса документов $\mathcal{D}$, S — множество шардов. Разбиение σ назначает каждому терму непустое множество шардов:

$$\sigma : T \to 2^S \setminus \{\varnothing\}, \quad D(d) = \bigcup_{t \in d} \sigma(t). \tag{1}$$

Документ d хранится в каждом шарде каждого своего терма; дублирование dup — среднее число шардов документа. Запрос q корректно обслуживается любым набором $S_q \subseteq S$, содержащим по шарду каждого терма запроса: объединение выдач шардов тогда воспроизводит выдачу полного индекса (2) при любом ранжировании, монотонном по документу.

$$\mathrm{Top}_k\Big(\bigcup_{s \in S_q} R_s(q)\Big) = \mathrm{Top}_k\big(R(q)\big). \tag{2}$$

Стоимость запроса складывается из числа опрашиваемых шардов (fanout) и доли просматриваемых документов (объём опроса); стоимость хранения — из дублирования и доли корпуса в крупнейшем шарде. Из правила хранения следует нижняя граница равномерности: шарды терма t содержат все его документы, поэтому

$$\mathrm{vol}(s) \geq \max_{t\,:\,s \in \sigma(t)} \mathrm{df}(t), \quad \mathrm{dup} = \frac{1}{|\mathcal{D}|} \sum_{d \in \mathcal{D}} |D(d)|. \tag{3}$$

Частые слова ограничивают достижимую равномерность снизу независимо от способа кластеризации. Задача — определить σ, доставляющее максимум качеству поиска при заданных ограничениях на перечисленные ресурсы.

Граф совстречаемости слов. Вершины графа — нормализованные слова обучающих запросов: нижний

регистр, стоп-слова, порог документной частоты от 2 до половины корпуса. Слова вопросной рамки (29 позиций: what, mean, difference и т. п.) исключены из графа: они совстречаются с большинством слов и не различают тематику. Ребро соединяет пару с числом совместных появлений не менее двух; вес ребра — NPMI [6]:

$$\mathrm{NPMI}(a,b) = \ln \frac{n(a,b)\,N}{n(a)\,n(b)} \Big/ \Big(-\ln \frac{n(a,b)}{N}\Big), \quad (4)$$

где $n(a)$, $n(b)$ — частоты слов, $n(a,b)$ — частоты пары, N — число появлений. Альтернативные веса G^2 [8] и χ^2 и вариации порогов проверены в разделе 5; качественные выводы от них не зависят.

Граф покрывает 5,6 % словаря корпуса (10 567 слов, 39 794 ребра, 289 компонент связности); размещение остальных слов определяют стратегии шардирования.

Построение кластеров. Кластеризация графа выполнена четырьмя алгоритмами. Leiden [10] максимизирует модулярность с разрешением γ:

$$Q_\gamma = \frac{1}{2m} \sum_{i,j} \Big[A_{ij} - \gamma \frac{k_i k_j}{2m}\Big]\, \delta(c_i, c_j). \quad (5)$$

CPM [11] оптимизирует качество constant Potts model с разрешением $\gamma = 0{,}02$; Infomap [13] минимизирует ожидаемую длину кода случайного блуждания; METIS [14] разрезает граф на 341 часть. Разрешение Leiden $\gamma = 1$ и остальные параметры алгоритмов зафиксированы до измерений (раздел 4.4). Алгоритм кластеризации — заменяемый компонент метода: он задаёт разбиение только слов графа, а распределение нагрузки по шардам определяется стратегиями следующего раздела.

Шардирование документов на основе кластеров. Стратегия `base` оставляет слова графа в шардах своих кластеров, а вне-графовые слова (94,4 % словаря) назначает хешем в отдельный диапазон идентификаторов. Стратегия `aff` присоединяет вне-графовое слово кластеру голосованием документов: берётся кластер со значимым превышением доли совместных документов (6), где $v(t,c)$ — число документов со словом t и словами кластера c, $m(c)$ — объём кластера; слова без значимых связей назначаются хешем.

$$c^*(t) = \arg\max_c \ \mathrm{sgn}\Big(\frac{v(t,c)}{v(t)} - \frac{m(c)}{m}\Big)\, G^2(t,c). \quad (6)$$

Реплики `aff_r2` и `aff_r3` дополнительно размещают слово графа в k чужих кластерах наибольшего сродства

$$\mathrm{aff}(t,c) = \sum_{(t,u)\in E,\ u\in c} w_{tu}, \quad (7)$$

что сокращает fanout ценой дублирования. Стратегии `hash_base`, `hash_aff`, `hash_bal` — случайные разбиения на то же число шардов, что у соответствующих семейств; они служат базовой линией.

Стратегия `bal` строится на разбиении `aff` и вводит бюджет объёма: доля корпуса в шарде не превосходит β (в измерениях $\beta = 15\,\%$). Сначала образуются единицы упаковки: кластер в пределах бюджета не дробится; кластер сверх бюджета рекурсивно делится тем же алгоритмом по собственным рёбрам с присоединением вне-графовых слов по значимости совместных документов, пока куски не войдут в бюджет; единица без структуры графа распадается на одиночные слова. Затем единицы, в порядке убывания объёма, упаковываются в шарды с минимальным приростом объёма при соблюдении бюджета:

$$s^*(u) = \arg \min_{s:\ \mathrm{vol}(s)+\Delta(u,s)\le\beta|\mathcal{D}|} \Delta(u,s), \quad (8)$$

где $\Delta(u,s) = |\mathcal{D}(u) \setminus \mathcal{D}(s)|$. Прирост минимален там, где документы единицы уже хранятся в шарде, поэтому упаковка объединяет единицы с пересекающимися документами и сдерживает рост дублирования; кластер в бюджете делит шард с другими единицами. Слово с $\mathrm{df}(t) > \beta|\mathcal{D}|$ образует шард независимо от остальных. Число шардов — следствие бюджета, а не параметр.

Маршрутизация запроса. Кандидаты опроса — шарды термов запроса. Их порядок задаёт жадное взвешенное покрытие [15]: на каждом шаге берётся шард, закрывающий наибольший суммарный вес непокрытых термов,

$$s_i = \arg\max_{s\in S} \sum_{t\in q\setminus C_{i-1},\ s\in\sigma(t)} w(t), \quad (9)$$

где $w(t) = \ln\big(|\mathcal{D}|/(\mathrm{df}(t)+1)\big) + 1$ — IDF терма [16]: сначала опрашиваются шарды редких слов, определяющих ранжирование. Бюджет опроса b ограничивает число шардов; b, равное мощности покрытия, даёт полный опрос. Алгоритм детерминирован: при равных весах порядок задаётся номером шарда.

Методика оценки

Датасет. Корпус собран из MS MARCO v2.1 [17]: релевантные фрагменты обучающих запросов дополнены дистракторами до 241 185 документов. Запросы (122 063) разделены в порядке датасета на обучающие (115 959) и отложенные (6 104) в отношении 95:5. Словарь корпуса — 189 841 слово, 26,2 терма на документ. Граф совстречаемости построен по обучающим запросам и содержит 10 567 слов и 39 794 ребра; крупнейшая компонента связности объединяет 9 972 слова, компонент — 289.

Оценочные выборки. Основная выборка — отложенные запросы. Обучающая используется для контроля переобучения графа. Смещённая выборка OOD — 10 000 вопросов Natural Questions [18], распределение которых отличается от построившего граф. Синтетические выборки по 2 000 запросов зависят только от графа и общи для всех алгоритмов: пары и тройки слов, встречающихся почти только вместе (connected), и наиболее частые пары и тройки (frequent). Число термов запроса — до пяти.

Метрики. Эталон выдачи — первые десять документов полного индекса, ранжированного BM25 ($k_1 = 1{,}2$, $b = 0{,}75$) [16]. Для каждого бюджета опроса $b \in \{1, 2, 3, 5, \text{полный}\}$ измеряются: доля эталонных доку-

ментов, найденных в опрошенных шардах (overlap),

$$\text{overlap@}k(q,b) = \frac{|R_k(q) \cap \mathcal{D}(S_q^{(b)})|}{k}; \qquad (10)$$

доля корпуса, просмотренная в опрошенных шардах (объём опроса); fanout — число шардов, покрывающих термы запроса; доля запросов, покрываемых одним шардом; дублирование; доля корпуса в крупнейшем шарде. Средние приводятся с 95 %-ми доверительными интервалами (бутстреп по запросам, 1 000 перевыборок); сравнения стратегий — как парные разности на одних и тех же запросах.

Расчёт выдачи шардов выполнен эмуляцией по выдаче полного индекса и сверен с физическими индексами Whoosh, построенными для шардов покрытий проверочных запросов: сопоставлено 1 594 686 оценок, максимальное расхождение $3{,}6 \cdot 10^{-15}$, расхождений выдачи 0. Дальнейшие измерения используют эмуляцию.

Сравниваемые конфигурации. Измерены десять стратегий (`hash_base`, `base`, `base_r2`, `base_r3`, `hash_aff`, `aff`, `aff_r2`, `aff_r3`, `hash_bal`, `bal`) на четырёх алгоритмах кластеризации. Основная конфигурация зафиксирована до измерений и не менялась: бюджет $\beta = 15\,\%$, разрешение Leiden $\gamma = 1$, разрешение CPM $\gamma = 0{,}02$, число частей METIS 341, зерно 42, вес рёбер NPMI, вес покрытия IDF. Каждая стратегия сравнивается со случайным разбиением на то же число шардов; чувствительность к зерну, объёму журнала и параметрам алгоритмов проверена отдельно.

Результаты

Сравнение стратегий. Семейства без бюджета покупают качество объёмом опроса и размером крупнейшего шарда (табл. 1). Стратегия `aff` даёт overlap@10 0,920 при опросе одного шарда против 0,651 у случайного разбиения, но её крупнейший шард хранит 83,1 % корпуса, первый опрос просматривает 59,5 % корпуса, а суммарный объём десяти крупнейших шардов — 6,7 корпуса. Дублирование при этом минимально среди всех стратегий: 10,0 против 25,7 у случайного разбиения — совстречаемые слова одного кластера, и документы, их содержащие, попадают в меньшее число шардов.

Вырождение устойчиво к настройкам. Среди 18 вариаций порогов графа, весов рёбер, стоп-листа и правила голосования ни одна не приводит крупнейший шард `aff` к 15-процентному бюджету ни при одном алгоритме; минимум по вариантам — 20,3 %. Ужесточение разрешения Leiden с $\gamma = 1$ до $\gamma = 20$ сокращает крупнейший шард до 18,4 %, но снижает overlap@10 до 0,746 и повышает дублирование до 21,0: параметр кластеризации не заменяет бюджет объёма.

Стратегия `bal` — единственная, укладывающаяся в бюджет. При равном числе шардов (132) она превосходит случайное разбиение `hash_bal` по всем измеренным метрикам: overlap@10 при опросе одного шарда 0,780 против 0,697 (парная разность +0,083, [0,077; 0,089]), объём опроса 15,0 % против 17,9 %, fanout 2,90 против 3,20, дублирование 19,8 против 23,6, крупнейший шард 15,0 % против 31,6 %. На смещённой выборке OOD прирост составляет +0,109 [0,104; 0,114]. Выбор устойчив: изменение разрешения Leiden от 1 до 50 меняет overlap@10 `bal` в пределах 0,763–0,780 при неизменном объёме шарда; смена зерна кластеризации — не более чем на 0,01.

Выбор конфигурации под профили нагрузки. Измеренная сетка конфигураций G (алгоритм, стратегия, бюджет опроса) допускает формальный выбор под ограничения эксплуатации. Для каждой конфигурации c известны качество $Q_b(c)$, fanout $F(c)$, дублирование $D(c)$, доля крупнейшего шарда и объём опроса при каждом бюджете. Профиль нагрузки p задаёт метрику M_p и её предельный уровень M_p^*: минимальный fanout, минимальное дублирование, предельная доля корпуса в шарде, предельный объём опроса. Конфигурация выбирается по правилу

$$c^*(p) = \arg\max_{c \in G_p} Q_b(c), \qquad G_p = \{c \in G : \; M_p(c) \le M_p^*, \; Q_b(c) \ge Q_b($$

(11)

где $H(c)$ — случайное разбиение на то же число шардов; условие $Q_b(c) \ge Q_b(H(c))$ отсекает конфигурации, при которых семантическое разбиение не окупается. Равные по качеству конфигурации различаются меньшим fanout и дублированием.

Применение правила к измеренной сетке даёт конфигурации табл. 2. Профиль минимального fanout активирует реплики: `aff_r3` снижает fanout до 1,85, запросы из совстречающихся слов целиком обслуживаются одним шардом, а качество достигает 0,962; плата — крупнейший шард 98,6 % и дублирование 13,8. Профиль минимального дублирования выбирает `aff`: дублирование 10,0 составляет 0,39 от случайного разбиения; плата — крупнейший шард 83,1 % и объём опроса 59,5 %. Профиль равномерных шардов реализуется только стратегией `bal`: доля крупнейшего шарда равна бюджету по построению, и никакая иная конфигурация сетки ограничению не удовлетворяет. Профиль фиксированного объёма опроса при допуске 15 % выбирает CPM с `aff` и полным покрытием: мелкие шарды CPM позволяют просмотреть всё покрытие за 14,2 % корпуса и получить точную выдачу при fanout 2,95; при допуске менее 5 % правило возвращает мелкошардовые случайные разбиения — нижняя граница применимости семантического шардирования по этой метрике.

Правило (11) и соответствие «ограничение эксплуатации — параметр метода» (fanout — реплики, дублирование — кластерная структура, равномерность — бюджет, объём опроса — размер шардов и бюджет опроса) не зависят от корпуса. Численные значения табл. 2 посчитаны для одного корпуса и одного журнала; перенос на другой корпус требует пересборки сетки тем же конвейером. Гарантии переносимы без пересчёта: доля крупнейшего шарда не превосходит β по построению, а сам β ограничен снизу частотой самого частого слова — 11,4 % для рассматриваемого корпуса.

Ограничения

Ранжирование предполагает глобальную статистику BM25 (частоты документов и среднюю длину), доступную всем шардам; локальная статистика изменила

Таблица 1. Стратегии шардирования на отложенной выборке, алгоритм Leiden
Table 1. Sharding strategies on the held-out sample, Leiden

Стратегия	Шардов	Дубл.	Макс. шард, %	Fanout	В 1 шард, %	Overlap@10		Объём опроса, %		
						@1	@2	@1	@2	полн.
`hash_base`	680	25,7	15,7	3,23	6,6	0,651	0,954	3,9	8,0	15,2
`base`	680	16,6	79,4	2,61	13,8	0,796	0,982	35,0	67,4	94,1
`base_r2`	680	19,3	95,9	2,31	19,6	0,839	0,989	52,1	89,2	110,3
`base_r3`	680	21,1	98,4	2,18	23,2	0,852	0,990	58,4	92,6	108,7
`hash_aff`	400	25,3	19,8	3,22	6,6	0,660	0,957	6,5	12,9	23,2
`aff`	400	10,0	83,1	2,31	22,7	0,920	0,997	59,5	104,5	136,5
`aff_r2`	400	12,2	96,4	1,98	31,3	0,952	0,999	75,7	126,8	149,4
`aff_r3`	400	13,8	98,6	1,85	36,5	0,962	0,999	82,4	132,6	150,1
`hash_bal`	132	23,6	31,6	3,20	6,7	0,697	0,966	17,9	35,3	60,1
`bal`	132	19,8	15,0	2,90	9,4	0,780	0,979	15,0	28,5	43,4

Таблица 2. Конфигурации, выбираемые правилом (11) *для четырёх профилей нагрузки, и случайное разбиение (отложенная выборка)*

Table 2. Configurations selected by rule (11) *for four workload profiles, and the random partition (held-out sample)*

Профиль	Конфигурация	Fanout	Дублир.	Крупн. шард, %	Объём опр., %
Минимальный fanout	Leiden, `aff_r3`, $b = 1$	1,85	13,8	98,6	82,4
Минимальное дублирование	Leiden, `aff`, $b = 1$	2,31	10,0	83,1	59,5
Равномерные шарды	Leiden, `bal`, $\beta = 15\,\%$, $b = 1$	2,90	19,8	15,0	15,0
Фиксированный объём опроса	CPM, `aff`, полное покрытие	2,95	21,6	32,0	14,2
случайное разбиение (`hash_base`)		3,23	25,7	15,7	3,9

бы выдачу и потребовал бы отдельной оценки. Дублирование порядка двадцати копий — следствие правила полноты (2): документ хранится в шардах всех своих термов; сокращение возможно только ценой потери гарантии совпадения выдачи. Совместная встречаемость измерена по журналу запросов: при холодном старте или малом журнале граф беднее — сокращение журнала со 116 до 10 тыс. запросов снижает overlap@10 `aff` с 0,920 до 0,837 и повышает дублирование с 10,0 до 14,2. Оценка стоимости выполнена прокси-метриками (число шардов, доля просмотренного корпуса), а не измеренными задержками; нагрузочные эффекты параллельного опроса не моделировались. Все значения получены на одном корпусе и одном языке.

Заключение

Предложен метод шардирования поискового индекса по словам на основе графа совстречаемости слов журнала запросов с бюджетом объёма шарда. Метод охватывает четыре заменяемых алгоритма кластеризации, голосование документов для вне-графовых слов, реплики по сродству и жадную IDF-взвешенную маршрутизацию; корректность эмуляции подтверждена сверкой с физическими индексами.

Измерения на корпусе MS MARCO из 241 185 документов дают три результата. Разбиения без бюджета объёма вырождаются: крупнейший шард достигает 83,1 % корпуса, и ни настройка кластеризации, ни 18 вариаций графа не приводят его к бюджету. Кластерная структура сокращает дублирование до 10,0 против 25,7 у случайного разбиения — главная выгода семантического шардирования. Сбалансированная стратегия `bal` при равном числе шардов превосходит случайную по всем метрикам: overlap@10 при опросе одного шарда 0,780 против 0,697, на смещённой выборке прирост +0,109.

Сформулировано правило выбора конфигурации под четыре профиля нагрузки; показано, что каждое ограничение эксплуатации отображается на один параметр метода. Дальнейшая работа: перебор бюджета β и его влияние на границы профилей, реплики сбалансированной стратегии для совместного профиля равномерности и fanout, измерение задержек на действующей системе и проверка на других корпусах и языках.

Литература

1. Kulkarni A., Callan J. Selective search: Efficient and effective search of large textual collections // ACM Transactions on Information Systems. 2015. V. 33. N 4. P. 17:1–17:33. https://doi.org/10.1145/2738035
2. Dai Z., Xiong C., Callan J. Query-biased partitioning for selective search // Proceedings of the 25th ACM International Conference on Information and Knowledge Management (CIKM). 2016. P. 1119–1128. https://doi.org/10.1145/2983323.2983706
3. Moffat A., Webber W., Zobel J., Baeza-Yates R. A pipelined architecture for distributed text query evaluation // Information Retrieval. 2007. V. 10. N 3. P. 205–231. https://doi.org/10.1007/s10791-006-9014-4

References

1. Kulkarni A., Callan J. Selective search: Efficient and effective search of large textual collections. *ACM Transactions on Information Systems*, 2015, vol. 33, no. 4, pp. 17:1–17:33. https://doi.org/10.1145/2738035
2. Dai Z., Xiong C., Callan J. Query-biased partitioning for selective search. *Proceedings of the 25th ACM International Conference on Information and Knowledge Management (CIKM)*, 2016, pp. 1119–1128. https://doi.org/10.1145/2983323.2983706
3. Moffat A., Webber W., Zobel J., Baeza-Yates R. A pipelined architecture for distributed text query evaluation. *Information Retrieval*, 2007, vol. 10, no. 3, pp. 205–231. https://doi.org/10.1007/s10791-006-9014-4

4. Risvik K.M., Chilimbi T., Tan H. et al. Maguro, a system for indexing and searching over very large text collections // Proceedings of the 6th ACM International Conference on Web Search and Data Mining (WSDM). 2013. P. 727–736. https://doi.org/10.1145/2433396.2433486
5. Moffat A., Webber W., Zobel J. Load balancing for term-distributed parallel retrieval // Proceedings of the 29th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval. 2006. P. 348–355. https://doi.org/10.1145/1148170.1148232
6. Bouma G. Normalized (pointwise) mutual information in collocation extraction // Proceedings of the Biennial GSCL Conference. 2009. P. 31–40.
7. Williams C.K.I. On suspicious coincidences and pointwise mutual information // Neural Computation. 2022. V. 34. N 10. P. 2037–2046. https://doi.org/10.1162/neco_a_01533
8. Dunning T. Accurate methods for the statistics of surprise and coincidence // Computational Linguistics. 1993. V. 19. N 1. P. 61–74. https://aclanthology.org/J93-1003
9. Newman M.E.J., Girvan M. Finding and evaluating community structure in networks // Physical Review E. 2004. V. 69. N 2. P. 026113. https://doi.org/10.1103/PhysRevE.69.026113
10. Traag V.A., Waltman L., van Eck N.J. From Louvain to Leiden: guaranteeing well-connected communities // Scientific Reports. 2019. V. 9. N 1. P. 5233. https://doi.org/10.1038/s41598-019-41695-z
11. Reichardt J., Bornholdt S. Statistical mechanics of community detection // Physical Review E. 2006. V. 74. N 1. P. 016110. https://doi.org/10.1103/PhysRevE.74.016110
12. Traag V.A., Van Dooren P., Nesterov Y. Narrow scope for resolution-limit-free community detection // Physical Review E. 2011. V. 84. N 1. P. 016114. https://doi.org/10.1103/PhysRevE.84.016114
13. Rosvall M., Bergstrom C.T. Maps of random walks on complex networks reveal community structure // Proceedings of the National Academy of Sciences. 2008. V. 105. N 4. P. 1118–1123. https://doi.org/10.1073/pnas.0706851105
14. Karypis G., Kumar V. A fast and high quality multilevel scheme for partitioning irregular graphs // SIAM Journal on Scientific Computing. 1998. V. 20. N 1. P. 359–392. https://doi.org/10.1137/S1064827595287997
15. Chvátal V. A greedy heuristic for the set-covering problem // Mathematics of Operations Research. 1979. V. 4. N 3. P. 233–235. https://doi.org/10.1287/moor.4.3.233
16. Robertson S., Zaragoza H. The probabilistic relevance framework: BM25 and beyond // Foundations and Trends in Information Retrieval. 2009. V. 3. N 4. P. 333–389. https://doi.org/10.1561/1500000019
17. Bajaj P., Campos D., Craswell N. et al. MS MARCO: A human generated MAchine Reading COmprehension dataset // arXiv preprint arXiv:1611.09268. 2016. https://doi.org/10.48550/arXiv.1611.09268
18. Kwiatkowski T., Palomaki J., Redfield O. et al. Natural Questions: a benchmark for question answering research // Transactions of the Association for Computational Linguistics. 2019. V. 7. P. 453–466. https://doi.org/10.1162/tacl_a_00276

4. Risvik K.M., Chilimbi T., Tan H. et al. Maguro, a system for indexing and searching over very large text collections. *Proceedings of the 6th ACM International Conference on Web Search and Data Mining (WSDM)*, 2013, pp. 727–736. https://doi.org/10.1145/2433396.2433486
5. Moffat A., Webber W., Zobel J. Load balancing for term-distributed parallel retrieval. *Proceedings of the 29th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, 2006, pp. 348–355. https://doi.org/10.1145/1148170.1148232
6. Bouma G. Normalized (pointwise) mutual information in collocation extraction. *Proceedings of the Biennial GSCL Conference*, 2009, pp. 31–40.
7. Williams C.K.I. On suspicious coincidences and pointwise mutual information. *Neural Computation*, 2022, vol. 34, no. 10, pp. 2037–2046. https://doi.org/10.1162/neco_a_01533
8. Dunning T. Accurate methods for the statistics of surprise and coincidence. *Computational Linguistics*, 1993, vol. 19, no. 1, pp. 61–74. https://aclanthology.org/J93-1003
9. Newman M.E.J., Girvan M. Finding and evaluating community structure in networks. *Physical Review E*, 2004, vol. 69, no. 2, pp. 026113. https://doi.org/10.1103/PhysRevE.69.026113
10. Traag V.A., Waltman L., van Eck N.J. From Louvain to Leiden: guaranteeing well-connected communities. *Scientific Reports*, 2019, vol. 9, no. 1, pp. 5233. https://doi.org/10.1038/s41598-019-41695-z
11. Reichardt J., Bornholdt S. Statistical mechanics of community detection. *Physical Review E*, 2006, vol. 74, no. 1, pp. 016110. https://doi.org/10.1103/PhysRevE.74.016110
12. Traag V.A., Van Dooren P., Nesterov Y. Narrow scope for resolution-limit-free community detection. *Physical Review E*, 2011, vol. 84, no. 1, pp. 016114. https://doi.org/10.1103/PhysRevE.84.016114
13. Rosvall M., Bergstrom C.T. Maps of random walks on complex networks reveal community structure. *Proceedings of the National Academy of Sciences*, 2008, vol. 105, no. 4, pp. 1118–1123. https://doi.org/10.1073/pnas.0706851105
14. Karypis G., Kumar V. A fast and high quality multilevel scheme for partitioning irregular graphs. *SIAM Journal on Scientific Computing*, 1998, vol. 20, no. 1, pp. 359–392. https://doi.org/10.1137/S1064827595287997
15. Chvátal V. A greedy heuristic for the set-covering problem. *Mathematics of Operations Research*, 1979, vol. 4, no. 3, pp. 233–235. https://doi.org/10.1287/moor.4.3.233
16. Robertson S., Zaragoza H. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 2009, vol. 3, no. 4, pp. 333–389. https://doi.org/10.1561/1500000019
17. Bajaj P., Campos D., Craswell N. et al. MS MARCO: A human generated MAchine Reading COmprehension dataset. *arXiv preprint arXiv:1611.09268*, 2016. https://doi.org/10.48550/arXiv.1611.09268
18. Kwiatkowski T., Palomaki J., Redfield O. et al. Natural Questions: a benchmark for question answering research. *Transactions of the Association for Computational Linguistics*, 2019, vol. 7, pp. 453–466. https://doi.org/10.1162/tacl_a_00276

Авторы

Постнов Степан Андреевич — студент, Университет ИТМО, Санкт-Петербург, 197101, Российская Федерация, stepaha78@gmail.com [ORCID]

Платонов Алексей Владимирович — кандидат технических наук, доцент, доцент, Университет ИТМО, Санкт-Петербург, 197101, Российская Федерация, https://orcid.org/0000-0002-8485-1296, avplatonov@itmo.ru

Саськов Лев Кириллович — Университет ИТМО, Санкт-Петербург, 197101, Российская Федерация [должность, ORCID, e-mail]

Authors

Stepan A. Postnov — Student, ITMO University, Saint Petersburg, 197101, Russian Federation, stepaha78@gmail.com

Alexey V. Platonov — PhD, Associate Professor, ITMO University, Saint Petersburg, 197101, Russian Federation, https://orcid.org/0000-0002-8485-1296, avplatonov@itmo.ru

Lev K. Saskov — ITMO University, Saint Petersburg, 197101, Russian Federation