УДК [000.000]

Метод построения распределенного поискового индекса на основе семантики запросов

Степан Андреевич Постнов[1], Алексей Владимирович Платонов[2], Лев Кириллович Саськов[3]

[1,2,3] Университет ИТМО, Санкт-Петербург, 197101, Российская Федерация
[1] s@pstnv.ru, [ORCID]
[2] avplatonov@itmo.ru, https://orcid.org/0000-0002-8485-1296
[3] [e-mail, ORCID]

Аннотация

Введение. Распределенный поисковый индекс может быть разбит между шардами по документам и по словам (термам). При разбиении по словам каждому терму назначается шард, а документ входит во все шарды своих термов, поэтому запрос из нескольких слов обслуживается несколькими шардами; при случайном назначении слов число опрашиваемых шардов приближается к длине запроса. Работа рассматривает размещение слов по шардам на основе семантической близости. **Метод.** Предложен метод шардирования на основе кластеров, построенных по графу совстречаемости слов журнала запросов. При маршрутизации опрашиваемые шарды выбираются жадным взвешенным покрытием. Реализация охватывает четыре алгоритма кластеризации и несколько стратегий назначения документов шардам. **Основные результаты.** Предложенный метод исследован на датасете MS MARCO. Оценены основные метрики сохранения выдачи и сформулированы правила выбора конфигурации под четыре профиля нагрузки: минимальное количество опрашиваемых шардов, минимальное дублирование документов, ограничение размера шардов, фиксированный объём опроса. **Обсуждение.** Метод демонстрирует потенциал для современных информационных систем, однако численные значения получены для одного корпуса и одного журнала запросов, поэтому в дальнейшем необходимо провести тестирование на нескольких датасетах различного размера.

Ключевые слова

поисковый индекс, инвертированный индекс, шардирование по словам, маршрутизация запросов, кластеризация графов, балансировка шардов

Ссылка для цитирования: []

Method for constructing a distributed search index based on query semantics

Stepan A. Postnov[1], Alexey V. Platonov[2], Lev K. Saskov[3]

[1,2,3] ITMO University, Saint Petersburg, 197101, Russian Federation
[1] s@pstnv.ru, [ORCID]
[2] avplatonov@itmo.ru, https://orcid.org/0000-0002-8485-1296
[3] [e-mail, ORCID]

Abstract

Introduction. A distributed search index can be split between shards by documents and by words (terms). When splitting by words, each term is assigned to a shard, while a document is included in all shards of its terms; therefore, a query containing several words is served by several shards; with random assignment of words, the number of shards queried approaches the length of the query. The work considers the distribution of words across shards based on semantic proximity. **Method.** A method for sharding based on clusters constructed from word co-occurrence in the query log is proposed. During routing, the queried shards are selected using greedy weighted covering. The implementation covers four clustering algorithms and several document assignment strategies to shards. **Main results.** The proposed method was evaluated using the MS MARCO dataset. The main metrics of result preservation were evaluated, and the rules for selecting a configuration for four load profiles have been formulated: the minimum number of shards to be queried, minimal duplication of documents, a limit on shard size, and a fixed probed volume. **Discussion.** The method demonstrates potential for modern information systems; however, the numerical values were obtained for a single corpus and a single query log, so in the future it will be necessary to conduct testing on several datasets of varying sizes.

Keywords

search index, inverted index, word-based sharding, query routing, graph clustering, shard balancing

For citation: []

© Постнов С.А., Платонов А.В., Саськов Л.К., 2026

Введение

Существует два основных способа назначения документам шардов в распределенном поисковом индексе: по документам и по словам (термам). При разбиении по документам каждый шард содержит подвыборку корпуса и весь словарь, а запрос направляется в несколько шардов, отобранных по оценке распределения релевантных документов (селективный поиск) [1, 2]. При классическом разбиении по словам (термам) словарь разрезается между шардами, поэтому инвертированный список конкретного терма целиком хранится в одном шарде. Такое хранение лежит в основе конвейерных систем распределённого вычисления запроса [3]. Разбиение словаря исключает дублирование постингов, однако запрос из m слов затрагивает шарды всех своих термов, поэтому маршрутизация становится узким местом при обращении к индексу.

Назначение слов по хешу не требует настройки, но игнорирует структуру нагрузки, из-за чего слова одного запроса попадают в разные шарды, поэтому число опрашиваемых шардов сравнимо с длиной запроса. Если же размещать в одном шарде слова, встречающиеся в одних запросах, запрос целиком обслуживается одним шардом. Сведения о совместной встречаемости даёт журнал запросов, который поисковая система накапливает в процессе работы; построение графа совстречаемости не требует разметки и дополнительного обхода корпуса.

В настоящей работе предложен метод построения распределенного поискового индекса на основе семантики запросов, который позволяет увеличить качество выдачи полного индекса в сравнении со случайным разбиением слов. В исследуемой схеме каждый шард индексирует полные документы, содержащие назначенные ему термы.

Связанные работы

В селективном поиске тематически группируются документы [1]; журнал запросов может использоваться для инициализации кластеризации и изменения меры сходства [2]. В терм-распределенной архитектуре исследовалось конвейерное выполнение запросов [3]. Наиболее близка рассматриваемой постановке гиперграфовая модель [4]: термы представлены вершинами, запросы — гиперребрами, а размещение учитывает взаимодействие серверов и нагрузку обработки списков. Используемый здесь граф сохраняет только парные связи и не представляет запрос отдельным гиперребром.

Для оценки связей применяется NPMI [5]; склонность PMI давать высокие оценки редким сочетаниям [6] учитывается введением порога числа совстречаемостей. Присоединение оставшегося словаря использует статистику отношения правдоподобия [7]. Отличие исследуемой схемы — сочетание такого назначения термов с хранением полных документов и ограничением их числа в шарде. Сравнение с хеш-разбиением оценивает эффект размещения внутри этой модели; прямое экспериментальное сопоставление с указанными распределенными системами не проводится.

Метод

Постановка задачи. Пусть $\mathcal{D}$ — корпус из n документов, T — словарь, S — множество шардов, $T(d)$ — различные термы документа. Назначение термов σ и правило хранения задаются выражениями

$$\sigma : T \to 2^S \setminus \{\varnothing\}, \quad A(d) = \bigcup_{t \in T(d)} \sigma(t), \quad \mathcal{D}_s = \{d \in \mathcal{D} : s \in A(d)\}. \tag{1}$$

Каждый шард индексирует полные тексты $\mathcal{D}_s$. Назначение терма определяет гарантированное размещение содержащих его документов, а не единственное место хранения его постингов.

Полное покрытие запроса q — упорядоченный набор $C(q) = (s_1, \ldots, s_f)$, содержащий хотя бы один шард из $\sigma(t)$ для каждого $t \in T(q) \cap T$. Длина покрытия $F(q) = f$ далее называется fanout. При бюджете b опрашиваются первые $\min(b, f)$ шардов; их множество обозначено $C_b(q)$. Для дизъюнктивного запроса любой найденный документ содержит терм t запроса и по (1) присутствует в шарде этого терма. Поэтому полное покрытие возвращает то же множество кандидатов, что и полный индекс.

Используется ранжирование BM25 [8] с общей статистикой коллекции: числом документов, документными частотами и средней длиной документа. Полный текст сохраняет локальные частоты и длину документа, поэтому его оценка одинакова во всех шардах. После удаления дубликатов выдача полного покрытия совпадает с эталонной при согласованном разрешении равных оценок.

Граф совстречаемости слов. Граф строится по обучающим запросам. Отбираются слова из букв длиной от двух символов с частотой от двух запросов до половины журнала, кроме общего стоп-листа и 29 слов вопросной рамки, например mean, definition, cost. Запросы с одинаковыми непустыми наборами отобранных слов учитываются один раз. Если N — число таких наборов, $n(a)$ и $n(a, b)$ — частоты слова и пары, вес ребра равен

$$w(a, b) = \frac{\ln \dfrac{n(a, b)N}{n(a)n(b)}}{-\ln \dfrac{n(a, b)}{N}}. \tag{2}$$

Сохраняются ребра с $n(a, b) \geq 2$ и $w(a, b) \geq 0$; вершинами служат их концы. Здесь семантическая близость означает статистическую совстречаемость; частоты повторных пользовательских обращений после дедупликации не сохраняются.

Построение кластеров. Сравниваются Leiden [9] с модулярностью и параметром разрешения $\gamma = 1$ [10], Leiden с критерием Constant Potts Model (CPM), $\gamma = 0{,}02$ [11], Infomap с минимизацией длины описания случайного блуждания [12] и METIS, строящий части с

близким числом вершин и малым весом разреза [13]. Для Leiden и CPM выполняется до 200 проходов до прекращения улучшения; для METIS заданы 341 часть и целочисленные веса с максимумом 1000. Баланс по числу вершин не ограничивает число документов в шарде.

Шардирование документов на основе кластеров. В стратегии `base` терм графа назначается кластеру, а остальные термы — по MD5-хешу в отдельный диапазон $[K, 2K)$, где K — размер пространства номеров кластеров.

В `aff` оставшийся терм t присоединяется по документам: каждый содержащий его документ подает по голосу за каждое свое различное слово графа. Пусть $v(t,c)$ — голоса за кластер c, $m(c)$ — число таких голосов по всему корпусу, $v_t = \sum_c v(t,c)$ и $m = \sum_c m(c)$. Для кластеров с ненулевыми голосами вычисляется статистика G^2 таблицы с ячейками $v(t,c)$, $v_t - v(t,c)$, $m(c) - v(t,c)$ и $m - v_t - m(c) + v(t,c)$. При недопредставленности относительно независимости ей присваивается отрицательный знак. Выбирается максимум знакового G^2; равенство разрешается по меньшему номеру кластера. Это мера ассоциации, а не проверка статистической гипотезы, поскольку голоса зависимы. Термы без голосов размещаются по хешу, как в `base`.

Стратегия `bal` преобразует `aff` под ограничение $|\mathcal{D}_s| \le \beta n$, где $\beta = 0{,}15$. Крупный кластер рекурсивно делится тем же алгоритмом на собственном подграфе; остальные термы присоединяются к частям по знаковому G^2. Если разделения нет, повышается разрешение Leiden/CPM или число частей METIS. Предусмотрено до пяти попыток уточнения на уровне и до 12 уровней; Infomap не имеет параметра уточнения. При исчерпании возможностей единица делится на отдельные термы. Термы резервного хеш-диапазона образуют отдельные единицы. Полученные единицы упорядочиваются по убыванию объема и помещаются в допустимый шард с минимальным приростом числа документов. Вместимость проверяется по объединению документов; если подходящего шарда нет, создается новый.

Число шардов определяется упаковкой, оптимальность которой не предполагается. Соблюдение бюджета возможно при

$$\beta \ge \max_{t \in T} \frac{\mathrm{df}(t)}{n}, \tag{3}$$

поскольку шард назначенного терма содержит все документы с этим термом. Если условие нарушено, частый терм образует отдельный шард с превышением бюджета. В исследуемом корпусе правая часть равна 0,1137, поэтому бюджет 0,15 допустим.

Варианты `base_r2`, `base_r3`, `aff_r2`, `aff_r3` добавляют термам графа до одного или двух размещений в чужих кластерах с наибольшей суммой весов связей. Документы копируются согласно (1). Репликация `bal` не исследуется.

Маршрутизация запроса. Из множества еще не покрытых термов U жадно выбирается шард

$$s^* = \arg\max_{s \in S} \sum_{t \in U} \mathbf{1}[s \in \sigma(t)]\, \mathrm{idf}(t). \tag{4}$$

Используется IDF Whoosh: $\ln(n/(\mathrm{df}(t)+1))+1$. После выбора покрытые термы удаляются из U; при равенстве выигрышей берется меньший номер шарда. Процедура задает полное покрытие и порядок опроса с приоритетом редких термов; минимальность длины покрытия не гарантируется.

Методика оценки

Датасет. Из первых 200 000 строк MS MARCO v2.1 [14] отбираются строки с отмеченным асессором пассажем и до двух различных пассажей на строку: сначала отмеченные, затем остальные в исходном порядке. Совпадающие нормализованные тексты объединяются. Получены 241 185 документов и 122 063 уникальных запроса. Это специально сформированный подкорпус, а не полный стандартный корпус ранжирования MS MARCO. Индекс и маршрутизатор используют нижний регистр, последовательности букв и цифр длиной от двух символов и общий стоп-лист без стемминга. Словарь содержит 189 841 терм, в среднем 26,204 различных терма на документ.

Оценочные выборки. Первые по порядку источника 95 % запросов (115 959) образуют обучающий журнал, остальные 6104 — основную отложенную выборку `holdout`. Разделение не случайное и не хронологическое; документы обеих частей доступны при построении размещения. Граф содержит 10 567 вершин и 39 794 ребра; его слова покрывают 5,56 % словаря корпуса. Для оценки дополнительно отбираются 10 000 обучающих запросов и 10 000 вопросов набора `nq_open`, производного от Natural Questions [15] (`ood`); последние выполняются на том же корпусе без переобучения.

Четыре диагностические выборки по 2000 запросов содержат пары и тройки слов графа: наиболее связанные по NPMI или наиболее частые по совстречаемости. Тройка получается добавлением общего соседа, максимизирующего минимум двух связей с парой. Эти выборки одинаковы для всех алгоритмов, но благоприятны для метода по построению. После исключения запросов с пустой эталонной выдачей остаются 6093 отложенных, 9980 обучающих, 10 000 внешних и 8000 синтетических запросов, всего 34 073.

Метрики. Эталон $R_k(q)$ — первые $k = 10$ документов полного индекса Whoosh при дизъюнктивном запросе и BM25 ($k_1 = 1{,}2$, $b_{\mathrm{BM25}} = 0{,}75$); при меньшем числе совпадений берутся все. Измеряются доля доступных документов эталонной десятки и суммарный объем выбранных шардов:

$$\begin{aligned} Q_b(q) &= \frac{|R_k(q) \cap \bigcup_{s \in C_b(q)} \mathcal{D}_s|}{|R_k(q)|}, \\ V_b(q) &= \frac{1}{n} \sum_{s \in C_b(q)} |\mathcal{D}_s|. \end{aligned} \tag{5}$$

Среднее Q_b называется overlap@10 и оценивает сохранение эталонной выдачи, а не релевантность по асессорской разметке. В V_b копии документа учитываются повторно; это характеристика размера локальных

коллекций, а не измеренная задержка или число просмотренных постингов. Дополнительно рассчитываются средний fanout F, доля запросов с $F(q) = 1$, дублирование D и доля крупнейшего шарда L:

$$D = \frac{1}{n} \sum_{d \in \mathcal{D}} |A(d)|, \qquad L = \max_s \frac{|\mathcal{D}_s|}{n}. \tag{6}$$

Фактическое число обращений при бюджете b равно $\min(b, F(q))$.

Сравниваются бюджеты $b \in \{1, 2, 3, 5\}$ и полное покрытие. Для средних и парных разностей на одинаковых запросах строятся 95 %-е процентильные бутстреп-интервалы по 1000 повторных выборок [16].

Сравниваемые конфигурации. Основная сетка содержит 40 размещений: четыре алгоритма, семь семантических стратегий и три хеш-разбиения с числом шардов соответствующих семейств `base`, `aff`, `bal`. Основное начальное значение генераторов равно 42; для кластеризации дополнительно проверяются 1, 2, 3, объемы журнала 10 000, 30 000, 70 000 и собственные параметры алгоритмов. Исследуются также 18 изменений правил голосования, маршрутизации, весов и порогов графа относительно основной настройки. Анализ вариантов использует ту же отложенную выборку; интервалы не учитывают множественные сравнения и неопределенность выбора размещения.

Результаты

Сравнение стратегий. Для Leiden присоединение термов по документам уменьшает число слов резервного хеш-диапазона со 179 279 до 67. Переход от `base` к `aff` сокращает дублирование с 16,57 до 9,97 копии и fanout с 2,610 до 2,306, но увеличивает средний объем первого шарда с 35,02 до 59,49 % корпуса (табл. 1). Репликация `aff_r3` дает $Q_1 = 0{,}9620$ и $F = 1{,}851$, однако крупнейший шард охватывает 98,60 % корпуса. Следовательно, высокое сохранение выдачи при одном обращении может достигаться поиском в почти полном корпусе.

Таблица 1. Стратегии шардирования для Leiden на отложенной выборке при опросе одного шарда
Table 1. Sharding strategies for Leiden on the held-out sample when probing one shard

Стратегия	Шарды	D	L, %	F	$F(q) = 1$, %	V_1, %	Q_1
`hash_base`	680	25,66	15,71	3,226	6,56	3,86	0,6507
`base`	680	16,57	79,43	2,610	13,79	35,02	0,7962
`base_r2`	680	19,34	95,89	2,308	19,63	52,11	0,8394
`base_r3`	680	21,14	98,42	2,184	23,24	58,35	0,8515
`hash_aff`	400	25,31	19,84	3,221	6,60	6,47	0,6601
`aff`	400	9,97	83,06	2,306	22,65	59,49	0,9202
`aff_r2`	400	12,21	96,42	1,982	31,25	75,72	0,9519
`aff_r3`	400	13,76	98,60	1,851	36,50	82,37	0,9620
`hash_bal`	132	23,59	31,61	3,204	6,65	17,94	0,6974
`bal`	132	19,78	15,00	2,895	9,35	14,97	0,7804

У CPM, Infomap и METIS крупнейшие шарды `aff` меньше, но также превышают бюджет: 32,00; 36,26 и 25,53 % корпуса. Ни в одном измеренном варианте настройки `aff` крупнейший шард не укладывается в бюджет 15 %. Стратегия `bal` соблюдает его во всех основных конфигурациях и формирует 132–140 шардов при исходных 335–2211 кластерах.

При одинаковом числе шардов `bal` улучшает Q_1, объем опроса, дублирование и длину покрытия у всех четырех алгоритмов (табл. 2). Для Leiden парный прирост Q_1 равен 0,0830 с 95 %-м интервалом $[0{,}0771; 0{,}0889]$; разность V_1 равна $-0{,}0297$ доли корпуса, интервал $[-0{,}0306; -0{,}0288]$. Прирост Q_1 у CPM, Infomap и METIS составляет 0,0612; 0,0717 и 0,0449, соответствующие интервалы также не содержат нуль.

Таблица 2. Сбалансированная стратегия и хеш-разбиение при равном числе шардов: отложенная выборка, бюджет одного шарда
Table 2. Balanced strategy and hash baseline with equal shard counts: held-out sample, one-shard budget

Алгоритм	Стратегия	Шарды	D	L, %	F	V_1, %	Q_1
Leiden	`bal`	132	19,78	15,00	2,895	14,97	0,7804
	`hash_bal`	132	23,59	31,61	3,204	17,94	0,6974
CPM	`bal`	136	20,38	15,00	2,941	14,94	0,7583
	`hash_bal`	136	23,65	31,58	3,200	17,47	0,6971
Infomap	`bal`	134	20,06	15,00	2,905	14,94	0,7699
	`hash_bal`	134	23,64	28,31	3,201	17,76	0,6982
METIS	`bal`	140	20,91	15,00	3,054	14,93	0,7431
	`hash_bal`	140	23,77	26,28	3,201	17,04	0,6982

С ростом бюджета различия по overlap сокращаются (рис. 1). Для Leiden при двух шардах $Q_2 = 0{,}9787$ против 0,9658, а $V_2 = 28{,}55\,\%$ против 35,26 %. При пяти шардах оба округленных Q_5 равны 0,9999. Полное покрытие дает $Q_{\text{full}} = 1$ для обеих стратегий, но объем равен 43,38 % у `bal` против 60,13 % у хеш-разбиения, на 27,86 % меньше.

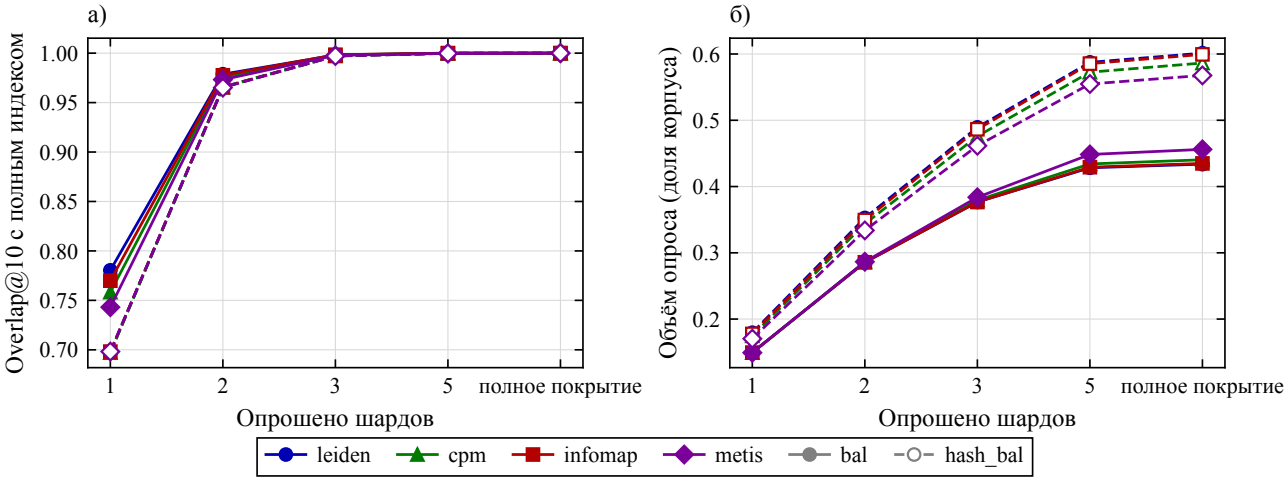


Рис. 1. Доля сохраненной выдачи (а) и объем опроса (б) в зависимости от бюджета: `bal` и `hash_bal`, отложенная выборка
Fig. 1. Reference-result retention (a) and probed volume (b) versus shard budget: `bal` and `hash_bal`, held-out sample

На запросах другого источника (`ood`) у Leiden $Q_1 = 0{,}6638$ против 0,5551: прирост 0,1087 с интервалом [0,1035; 0,1141]. Fanout равен 4,200 против 4,566, объем первого шарда — 14,96 % против 17,95 %. Прирост сохраняется у остальных алгоритмов: от 0,0599 у METIS до 0,1060 у Infomap. У Leiden для связанных пар `bal` покрывает запрос одним шардом в 98,80 % случаев против 0,80 %; для связанных троек — в 49,30 % против нуля. У частотных пар Q_1 почти единично уже при хеш-разбиении: полный документ может находиться в выбранном шарде, хотя не все термы запроса назначены этому шарду.

У Leiden срезы отложенной выборки выявляют рост преимущества с длиной и связностью запроса. Для двух термов прирост Q_1 равен 0,0376, для пяти и более — 0,1508. В верхней группе по средней NPMI между термами $Q_1 = 0{,}9498$ против 0,8467, в нижней — 0,8366 против 0,8268. Для 4221 запроса хотя бы с одним словом вне графа получено 0,7422 против 0,6503; их размещение определяется присоединением по документам. Отдельные интервалы для этих срезов не рассчитывались.

При четырех начальных значениях генератора размах Q_1 стратегии `bal` не превышает 0,0024 у каждого алгоритма. При увеличении журнала с 10 000 до 115 959 запросов у Leiden Q_1 меняется с 0,7759 до 0,7804; у других алгоритмов зависимость немонотонна. Разрешение Leiden от 1 до 50 меняет число исходных кластеров с 340 до 1110, но число сбалансированных шардов остается в пределах 132–136, а Q_1 — 0,7627–0,7804.

Единой лучшей абляции нет. Замена знакового G^2 числом голосов уменьшает Q_1 у всех алгоритмов. Лучший измеренный вариант Leiden (веса G^2, отсутствие фильтра рамки, порог трех совстречаемостей) дает 0,7909 вместо 0,7804, но у CPM та же настройка снижает показатель с 0,7583 до 0,7340. Эти результаты характеризуют чувствительность; выбор лучшей настройки требует независимой тестовой выборки.

Для всех 40 размещений независимо проверены назначения документов и покрытия всех 34 073 оцениваемых запросов; расхождений нет. Для пяти случайных отложенных запросов на алгоритм построены физические индексы шардов и сопоставлены оценки BM25 и объединенные выдачи при каждом бюджете с расчетной моделью. В 1 594 686 сравнениях максимальное расхождение оценки составило $3{,}553 \cdot 10^{-15}$ при допуске 10^{-9}; выдачи совпали с точностью до перестановок равных оценок. Расчет Q_b по принадлежности документов эталонной десятки выбранным шардам является точным и не требует построения всех локальных индексов.

Выбор конфигурации под профили нагрузки. Пусть G — основная измеренная сетка «алгоритм, стратегия, бюджет», $H(c)$ — соответствующее хеш-разбиение, а G_p — семантические конфигурации, удовлетворяющие ограничениям профиля p и условию $Q_b(c) \geq Q_b(H(c))$. Выбирается

$$c^*(p) = \arg\max_{c \in G_p} Q_{b(c)}(c), \qquad (7)$$

при равенстве — с меньшим fanout, затем дублированием. Правило ограничено измеренной сеткой и средними значениями. Четыре примера сведены в табл. 3; первые три используют $b = 1$, последний допускает все бюджеты.

Таблица 3. Выбор конфигурации при четырех наборах ограничений на отложенной выборке
Table 3. Configuration selection under four sets of constraints on the held-out sample

Ограничение	Конфигурация	F	D	V_b, %	Q_b
$F \le 2$, $b = 1$	Leiden, `aff_r3`	1,851	13,76	82,37	0,9620
$D \le 10$, $b = 1$	Leiden, `aff`	2,306	9,97	59,49	0,9202
$L \le 0{,}15$, $b = 1$	Leiden, `bal`	2,895	19,78	14,97	0,7804
$V_b \le 0{,}15$	CPM, `aff`, полное покрытие	2,945	21,62	14,25	1,0000

Ограничения на fanout и хранение выбирают несбалансированные Leiden `aff_r3` и `aff`, допуская крупные локальные коллекции. Ограничение $L \le 0{,}15$ выбирает `bal`. При $V_b \le 0{,}15$ выбирается CPM `aff` с полным покрытием; его хеш-разбиение также имеет $Q_{\text{full}} = 1$ и меньший объем (6,86 %), но больший fanout (3,232 против 2,945). Поэтому последний выбор определяется правилом разрешения равенства, а не преимуществом по всем затратам. Ограничение среднего объема не ограничивает размер каждого шарда: у выбранной CPM-конфигурации $L = 32{,}00$ %.

Ограничения

Результаты получены на одном англоязычном подкорпусе с отбором пассажей по асессорским отметкам. Отложены запросы, а не документы; внешний набор также проверяется на том же корпусе. Overlap характеризует сохранение BM25-выдачи и не доказывает улучшения релевантности. Синтетические запросы и анализ вариантов не заменяют независимого тестирования.

Точность восстановления предполагает общую статистику BM25 и хранение полных документов: в сбалансированных конфигурациях это 19,78–20,91 копии на документ. Объем и fanout не определяют задержку, размер сжатого индекса или баланс потока запросов. Обновления, отказы и другие типы поиска не исследуются; прямое сравнение с гиперграфовым разбиением и селективным поиском требует отдельного эксперимента.

Код, параметры, контрольные суммы DVC и результаты доступны в https://github.com/pstpn/sharded-semantic-index. Числа статьи соответствуют таблицам `metrics`; параметры и версии зависимостей зафиксированы в `params.yaml` и `requirements.lock`.

Заключение

Граф совстречаемости запросов позволяет уменьшить число обращений и потери эталонной выдачи, но без объемного ограничения формирует крупные шарды. Предложенная процедура дробления и упаковки ограничивает размер шарда при условии (3) и сохраняет полноту поиска при полном покрытии. На 241 185 документах сбалансированный Leiden при 132 шардах повышает overlap@10 одного шарда с 0,6974 до 0,7804, одновременно сокращая объем опроса с 17,94 до 14,97 % и дублирование с 23,59 до 19,78 копии. Преимущество при одном обращении сохраняется у всех четырех алгоритмов и на запросах другого источника. Выбор размещения требует совместного учета ограничений на хранение, fanout и объем, а оценка практической эффективности — независимых корпусов и измерения задержек физических шардов.

Литература

1. Kulkarni A., Callan J. Selective search: Efficient and effective search of large textual collections // ACM Transactions on Information Systems. 2015. V. 33. N 4. P. 17:1–17:33. https://doi.org/10.1145/2738035
2. Dai Z., Xiong C., Callan J. Query-biased partitioning for selective search // Proc. of the 25th ACM International Conference on Information and Knowledge Management. 2016. P. 1119–1128. https://doi.org/10.1145/2983323.2983706
3. Moffat A., Webber W., Zobel J., Baeza-Yates R. A pipelined architecture for distributed text query evaluation // Information Retrieval. 2007. V. 10. N 3. P. 205–231. https://doi.org/10.1007/s10791-006-9014-4
4. Cambazoglu B.B., Kayaaslan E., Jonassen S., Aykanat C. A term-based inverted index partitioning model for efficient distributed query processing // ACM Transactions on the Web. 2013. V. 7. N 3. P. 15:1–15:23. https://doi.org/10.1145/2516633.2516637
5. Bouma G. Normalized (pointwise) mutual information in collocation extraction // From Form to Meaning: Processing Texts Automatically. Proc. of the Biennial GSCL Conference. Tübingen: Gunter Narr, 2009. P. 31–40. https://svn.spraakdata.gu.se/repos/gerlof/pub/www/Docs/npmi-pfd.pdf
6. Williams C.K.I. On suspicious coincidences and pointwise mutual information // Neural Computation. 2022. V. 34. N 10. P. 2037–2046. https://doi.org/10.1162/neco_a_01533

References

1. Kulkarni A., Callan J. Selective search: Efficient and effective search of large textual collections. *ACM Transactions on Information Systems*, 2015, vol. 33, no. 4, pp. 17:1–17:33. https://doi.org/10.1145/2738035
2. Dai Z., Xiong C., Callan J. Query-biased partitioning for selective search. *Proc. of the 25th ACM International Conference on Information and Knowledge Management*, 2016, pp. 1119–1128. https://doi.org/10.1145/2983323.2983706
3. Moffat A., Webber W., Zobel J., Baeza-Yates R. A pipelined architecture for distributed text query evaluation. *Information Retrieval*, 2007, vol. 10, no. 3, pp. 205–231. https://doi.org/10.1007/s10791-006-9014-4
4. Cambazoglu B.B., Kayaaslan E., Jonassen S., Aykanat C. A term-based inverted index partitioning model for efficient distributed query processing. *ACM Transactions on the Web*, 2013, vol. 7, no. 3, pp. 15:1–15:23. https://doi.org/10.1145/2516633.2516637
5. Bouma G. Normalized (pointwise) mutual information in collocation extraction. *From Form to Meaning: Processing Texts Automatically. Proc. of the Biennial GSCL Conference*, Tübingen, Gunter Narr, 2009, pp. 31–40. https://svn.spraakdata.gu.se/repos/gerlof/pub/www/Docs/npmi-pfd.pdf
6. Williams C.K.I. On suspicious coincidences and pointwise mutual information. *Neural Computation*, 2022, vol. 34, no. 10, pp. 2037–2046. https://doi.org/10.1162/neco_a_01533

7. Dunning T. Accurate methods for the statistics of surprise and coincidence // Computational Linguistics. 1993. V. 19. N 1. P. 61–74. https://aclanthology.org/J93-1003
8. Robertson S., Zaragoza H. The probabilistic relevance framework: BM25 and beyond // Foundations and Trends in Information Retrieval. 2009. V. 3. N 4. P. 333–389. https://doi.org/10.1561/1500000019
9. Traag V.A., Waltman L., van Eck N.J. From Louvain to Leiden: guaranteeing well-connected communities // Scientific Reports. 2019. V. 9. N 1. P. 5233. https://doi.org/10.1038/s41598-019-41695-z
10. Reichardt J., Bornholdt S. Statistical mechanics of community detection // Physical Review E. 2006. V. 74. N 1. P. 016110. https://doi.org/10.1103/PhysRevE.74.016110
11. Traag V.A., Van Dooren P., Nesterov Y. Narrow scope for resolution-limit-free community detection // Physical Review E. 2011. V. 84. N 1. P. 016114. https://doi.org/10.1103/PhysRevE.84.016114
12. Rosvall M., Bergstrom C.T. Maps of random walks on complex networks reveal community structure // Proceedings of the National Academy of Sciences. 2008. V. 105. N 4. P. 1118–1123. https://doi.org/10.1073/pnas.0706851105
13. Karypis G., Kumar V. A fast and high quality multilevel scheme for partitioning irregular graphs // SIAM Journal on Scientific Computing. 1998. V. 20. N 1. P. 359–392. https://doi.org/10.1137/S1064827595287997
14. Bajaj P., Campos D., Craswell N., Deng L., Gao J., Liu X., Majumder R., McNamara A., Mitra B., Nguyen T., Rosenberg M., Song X., Stoica A., Tiwary S., Wang T. MS MARCO: A human generated MAchine Reading COmprehension dataset // arXiv. 2016. arXiv:1611.09268v3 (ред. 2018). https://doi.org/10.48550/arXiv.1611.09268
15. Kwiatkowski T., Palomaki J., Redfield O., Collins M., Parikh A., Alberti C., Epstein D., Polosukhin I., Devlin J., Lee K., Toutanova K., Jones L., Kelcey M., Chang M.-W., Dai A.M., Uszkoreit J., Le Q., Petrov S. Natural Questions: a benchmark for question answering research // Transactions of the Association for Computational Linguistics. 2019. V. 7. P. 453–466. https://doi.org/10.1162/tacl_a_00276
16. Efron B., Tibshirani R.J. An Introduction to the Bootstrap. Chapman & Hall/CRC, 1994. 456 p. https://doi.org/10.1201/9780429246593

Авторы

Постнов Степан Андреевич — студент, Университет ИТМО, Санкт-Петербург, 197101, Российская Федерация, s@pstnv.ru [ORCID]

Платонов Алексей Владимирович — кандидат технических наук, доцент, Университет ИТМО, Санкт-Петербург, 197101, Российская Федерация, https://orcid.org/0000-0002-8485-1296, avplatonov@itmo.ru

Саськов Лев Кириллович — Университет ИТМО, Санкт-Петербург, 197101, Российская Федерация [должность, ORCID, e-mail]

7. Dunning T. Accurate methods for the statistics of surprise and coincidence. *Computational Linguistics*, 1993, vol. 19, no. 1, pp. 61–74. https://aclanthology.org/J93-1003
8. Robertson S., Zaragoza H. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 2009, vol. 3, no. 4, pp. 333–389. https://doi.org/10.1561/1500000019
9. Traag V.A., Waltman L., van Eck N.J. From Louvain to Leiden: guaranteeing well-connected communities. *Scientific Reports*, 2019, vol. 9, no. 1, pp. 5233. https://doi.org/10.1038/s41598-019-41695-z
10. Reichardt J., Bornholdt S. Statistical mechanics of community detection. *Physical Review E*, 2006, vol. 74, no. 1, pp. 016110. https://doi.org/10.1103/PhysRevE.74.016110
11. Traag V.A., Van Dooren P., Nesterov Y. Narrow scope for resolution-limit-free community detection. *Physical Review E*, 2011, vol. 84, no. 1, pp. 016114. https://doi.org/10.1103/PhysRevE.84.016114
12. Rosvall M., Bergstrom C.T. Maps of random walks on complex networks reveal community structure. *Proceedings of the National Academy of Sciences*, 2008, vol. 105, no. 4, pp. 1118–1123. https://doi.org/10.1073/pnas.0706851105
13. Karypis G., Kumar V. A fast and high quality multilevel scheme for partitioning irregular graphs. *SIAM Journal on Scientific Computing*, 1998, vol. 20, no. 1, pp. 359–392. https://doi.org/10.1137/S1064827595287997
14. Bajaj P., Campos D., Craswell N., Deng L., Gao J., Liu X., Majumder R., McNamara A., Mitra B., Nguyen T., Rosenberg M., Song X., Stoica A., Tiwary S., Wang T. MS MARCO: A human generated MAchine Reading COmprehension dataset. *arXiv*, 2016, arXiv:1611.09268v3 (revised 2018). https://doi.org/10.48550/arXiv.1611.09268
15. Kwiatkowski T., Palomaki J., Redfield O., Collins M., Parikh A., Alberti C., Epstein D., Polosukhin I., Devlin J., Lee K., Toutanova K., Jones L., Kelcey M., Chang M.-W., Dai A.M., Uszkoreit J., Le Q., Petrov S. Natural Questions: a benchmark for question answering research. *Transactions of the Association for Computational Linguistics*, 2019, vol. 7, pp. 453–466. https://doi.org/10.1162/tacl_a_00276
16. Efron B., Tibshirani R.J. *An Introduction to the Bootstrap*. Chapman & Hall/CRC, 1994, 456 p. https://doi.org/10.1201/9780429246593

Authors

Stepan A. Postnov — Student, ITMO University, Saint Petersburg, 197101, Russian Federation, s@pstnv.ru [ORCID]

Alexey V. Platonov — PhD, Associate Professor, ITMO University, Saint Petersburg, 197101, Russian Federation, https://orcid.org/0000-0002-8485-1296, avplatonov@itmo.ru

Lev K. Saskov — ITMO University, Saint Petersburg, 197101, Russian Federation [position, ORCID, e-mail]